OBJECTIU
• Analitzar les mètriques de rendiment de YOLO
• Explorar la sortida d'un model YOLO preentrenat.
• Comprendre l'impacte de la naturalesa del conjunt de dades en el rendiment (canvi de domini)

Exercici 1. Rendiment de YOLO entrenat amb el conjunt de dades COCO. Avalua YOLOv8 amb el conjunt `real_data.zip` utilitzant l'script `yolo_v1.py`.

a) Estudia el flux de treball (pipeline) de YOLO: entrada, extracció de característiques, predicció de caixes delimitadores (bounding boxes), puntuacions de confiança i supressió de no-màxims (NMS).

entrada: la foto es redimensiona a 640 px (amb franges per mantenir la proporció).
extracció de característiques: una xarxa convolucional (backbone) treu mapes de característiques a 3 escales (objectes petits, mitjans i grans).
predicció de caixes: per a cada punt d'aquests mapes, el head prediu una caixa (centre, amplada, alçada) i una puntuació per classe.
confiança: a YOLOv8 és la probabilitat de la classe. Per defecte es llencen les caixes per sota de 0'25.
NMS: un mateix objecte surt en moltes caselles veïnes. L'NMS es queda la caixa amb més confiança i elimina les que la solapen massa.

b) Explora la distribució dels objectes detectats i la seva puntuació de confiança utilitzant diagrames de caixa (boxplots) i histogrames.

Hem passat yolov8n per les fotos de train + validation i n'hem desat les caixes, la classe i la confiança. Els grups són (cv és real_data.zip):

cv frontal	18 fotos
cv lateral	41 fotos
own in	18 fotos
own out	20 fotos
rata	117 fotos
coco (amb cotxes)	12 fotos

Classes: La classe més detectada en tots els conjunts és «car»: surt en el 88–100 % de les nostres fotos (cv 88–89 %, own 100 %, rata 88 %) i en el 67 % de les de COCO amb cotxes. COCO no té la classe «matrícula», i a les nostres fotos el model també posa al cotxe classes properes, com truck, bus, motorcycle o fins i tot suitcase.

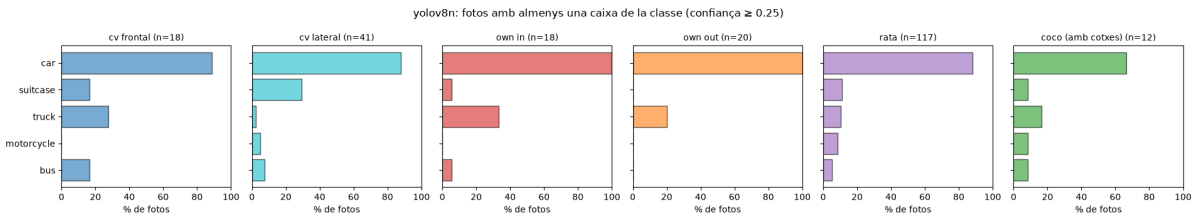

Confiança (boxplots): Cada punt és una caixa detectada. A les nostres fotos, car és la classe amb més confiança. Truck, bus i suitcase queden al voltant del llindar de 0,25 o per sota. A COCO, la mediana de car és baixa (0,13), perquè moltes caixes són cotxes petits del fons.

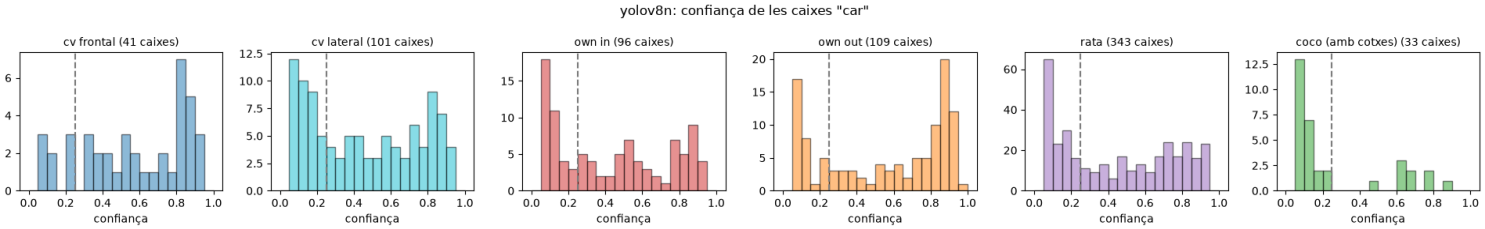

Confiança (histogrames de car): Les distribucions tenen dos pics: moltes caixes amb confiança molt baixa (< 0,2) i moltes amb confiança alta (0,8–0,9), i menys valors intermedis. A cv lateral i a rata la confiança es reparteix més. A COCO gairebé totes les caixes són per sota de 0,25.

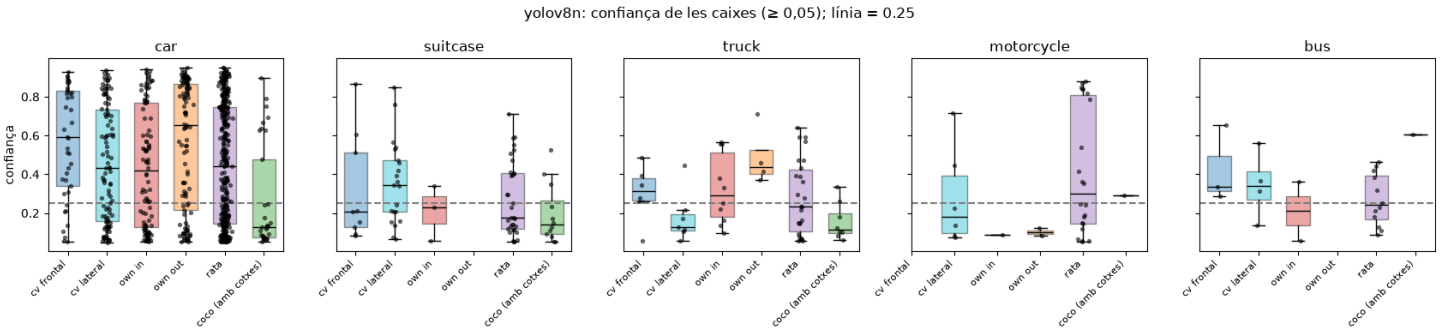

c) Visualitza les regions detectades.

cv frontal	cv lateral
No marca el cotxe principal, que ocupa gairebé tota la foto.	Marca el cotxe principal, i també el cotxe del costat.

own in	own out
	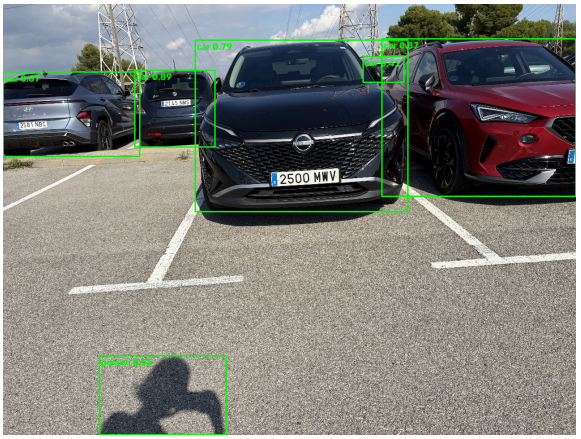
no s'equivoca i marca bé el cotxe i el del fons.	marca bé els cotxes, i també posa una caixa a l'ombra del fotògraf.
coco amb cotxes	**rata**
marca bé el rellotge (clock 0,80), però el cotxe petit del fons no surt.	marca bé el cotxe, amb una caixa que l'envolta sencer, però també confon amb suitcase.

d) El model detecta amb precisió tots els cotxes del nostre conjunt de dades o hi ha marge de millora? Avalua el model amb imatges de COCO que continguin cotxes. Per què creus que el model no ofereix el mateix rendiment amb les nostres dades?

Com que a les nostres fotos (cv, own i rata) no tenim anotada la caixa del cotxe però sí la matrícula, diem que el cotxe s'ha trobat si alguna caixa «car» amb confiança ≥ 0,25 conté el centre de la matrícula. A COCO tenim les caixes dels cotxes anotades, i un cotxe es troba si una caixa car el solapa amb IoU ≥ 0,5.

grup	cotxe trobat com a car	com a car/truck/bus	part de la foto que ocupa el cotxe
cv frontal	77,8 %	88,9 %	60,7 %
cv lateral	73,2 %	75,6 %	60,5 %
own in	94,4 %	100 %	53,4 %
own out	100 %	100 %	19,3 %
rata	79,5 %	84,6 %	56,1 %

COCO, mida del cotxe	cotxes	trobats
petit	40	10,0 %
mitjà	4	75,0 %
gran	2	100 %
tots	46	19,6 %

El model no detecta amb precisió els cotxes del nostre conjunt de dades. Troba com a car el 73–94 % dels cotxes fotografiats de prop (cv, own in, rata), i a molts dels altres els posa truck o bus. El model s'ha entrenat amb escenes de carrer on els cotxes surten sencers i petits; a les nostres fotos el cotxe ocupa més de la meitat de la imatge i surt tallat. Les fotos fetes de lluny (own out), on el cotxe surt sencer i ocupa el 19 % de la foto, s'assemblen més a COCO, i aquí troba el 100 %.

Exercici 2. Rendiment de YOLO entrenat amb imatges específiques de matrícules.
Repeteix l'anàlisi de l'Exercici 1 utilitzant el model `LP-detection.pt`.
Classes. El model té dues classes: matrícula d'una fila i de dues files.

- Single surt en gairebé totes les fotos de cv (94,4 % frontal, 97,6 % lateral) i en menys de les altres (72,2 % own in, 85,0 % own out, 80,3 % rata).
- Double gairebé no surt (0–11 % de les fotos). És normal, perquè gairebé totes les nostres matrícules són d'una fila. Les de dues files són poques motos de rata.

Ara hi ha aproximadament una caixa per foto (0,90–1,20), i no 2–4 com amb yolov8n: el model busca un sol objecte concret, la matrícula.

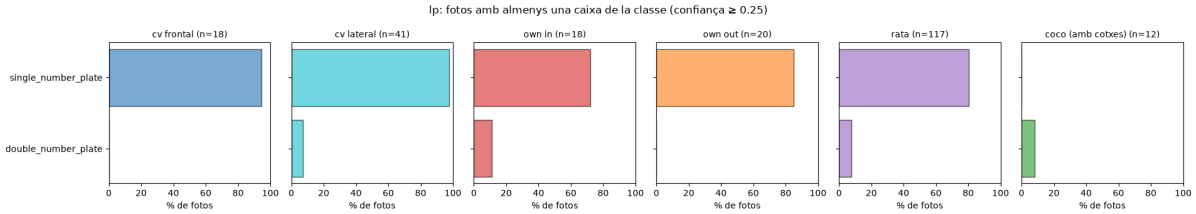

Confiança (boxplots):
Single té confiances altes a cv (medianes 0,78 frontal i 0,69 lateral) i a rata (0,69), i més baixes a own (0,52–0,53).
Double té gairebé sempre confiances per sota del llindar de 0,25. Són dubtes del model, i el llindar les descarta.
A COCO el model gairebé no troba res: 5 caixes single per sota de 0,25 i 1 caixa double amb 0,755. A la visualització es veu que s'ha confós amb un rètol.

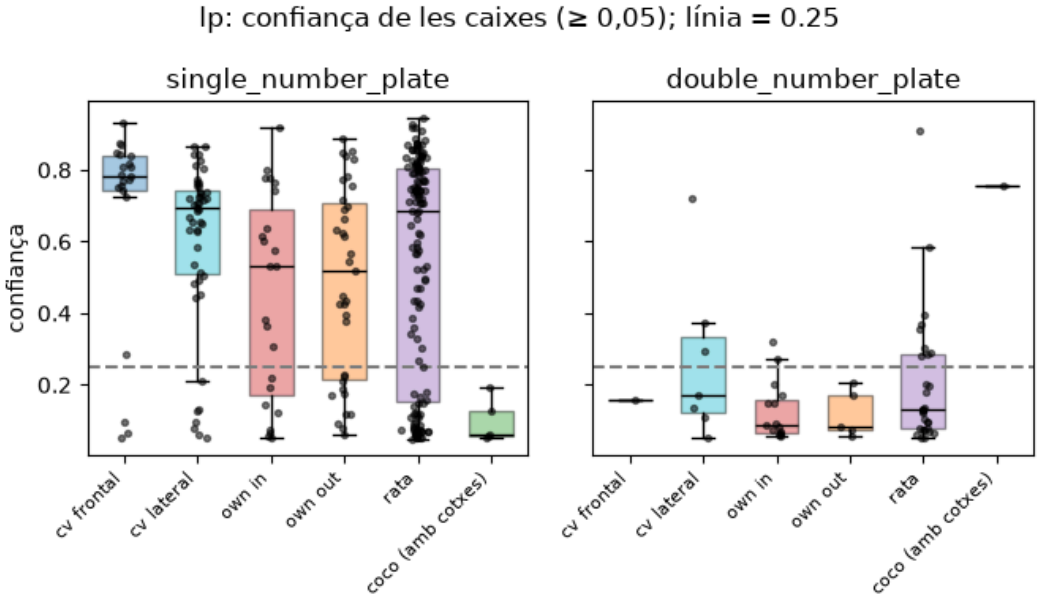

Confiança (histogrames de car):
cv frontal: gairebé totes les caixes són entre 0,7 i 0,95, més unes quantes de molt baixes. El model està segur.
cv lateral: el pic és cap a 0,7–0,8, amb una cua cap a valors més baixos.
rata: dos pics clars, un per sota de 0,15 i un altre entre 0,7 i 0,9.
own (in i out): les confiances es reparteixen per tot el rang. El model està menys segur amb les nostres fotos, tot i que les d'own in segueixen el mateix protocol que cv.

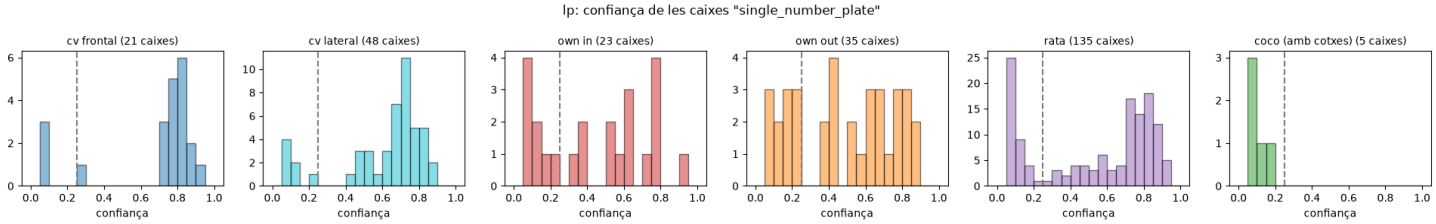

Visualitzacions:

cv frontal	cv lateral
own in	**own out**
No troba la matrícula.	troba la del davanti una del fons però no totes (com q la foto es redueix a 640 px, les del fons poden quedar il·legibles)
coco amb cotxes	**rata**
Fals positiu: el model confon text amb una matrícula.	

Ara el model sí que busca matrícules. Considerem trobada una matrícula si alguna caixa amb confiança ≥ 0,25 la solapa amb IoU ≥ 0,5. La IoU es calcula de dues maneres:

- contra el rectangle que envolta la matrícula anotada, que és la comparació justa per a YOLO, perquè només dona caixes rectes;
- contra el quadrilàter de les 4 cantonades, com a la S2.

grup	fotos	matrícules	trobades (rectangle)	trobades (quadrilàter)	caixes/foto	FP/foto
cv frontal	18	18	94,4 %	94,4 %	1,00	0,06
cv lateral	41	41	100 %	70,7 %	1,07	0,02
own in	18	18	83,3 %	50,0 %	0,94	0,11
own out	20	28	78,6 %	67,9 %	1,20	0,10
rata	117	117	84,6 %	70,9 %	0,90	0,05
COCO (amb cotxes)	12	–	–	–	0,08	–

A la fila de COCO hi ha guions perquè COCO no té les matrícules anotades: només podem comptar les caixes per foto.

A cv les troba gairebé totes, amb molt pocs falsos positius. Amb el quadrilàter el percentatge baixa sobretot a les laterals: la matrícula de costat surt inclinada i el rectangle recte de YOLO només la cobreix en part. La caixa és bona, però YOLO no pot donar la forma inclinada.

A own i a rata la detecció baixa al 79–85 %, tant dins com fora de protocol. És el mateix canvi de domini de l'Ex1: no depèn només de si la foto segueix el protocol, sinó també de les fotos amb què es va entrenar el model.

Comparació amb el detector clàssic (S2, mateixes fotos, quadrilàter):

	own in	own out	rata
detector clàssic (professors)	44 %	11 %	35 %
LP-detection	50,0 %	67,9 %	70,9 %

LP-detection és més robust, sobretot fora de protocol. Els errors que fa són de perspectiva i de mida, per això reentrenar amb fotos semblants a les nostres (següent exercici) hauria d'ajudar.

Exercici 3. Ajustament fi (fine-tuning) de YOLO. Reentrena `LP-detection.pt` i `yolov8n.pt` per adaptar els models al nostre conjunt de dades.

a) Utilitza la sortida del detector d'aprenentatge automàtic (ML) per definir una veritat de referència (GT).

No hem fet servir el detector clàssic per crear la GT. A la primera sessió vam fer una eina d'anotació (ground truth maker) on per a cada foto, es fa clic a les quatre cantonades de cada matrícula i se'n desa la posició i el text. Amb aquesta eina vam anotar totes les fotos de cv i les nostres (own). Les fotos d'uc3m ja venien anotades.
Una GT manual és més fiable que la sortida del detector clàssic ja que el detector perd matrícules i en troba de falses, i YOLO aprendria aquests errors. Com que YOLO treballa amb rectangles rectes, per entrenar fem servir el rectangle que envolta les quatre cantonades anotades. A la següent captura es veu una mica la interfície:

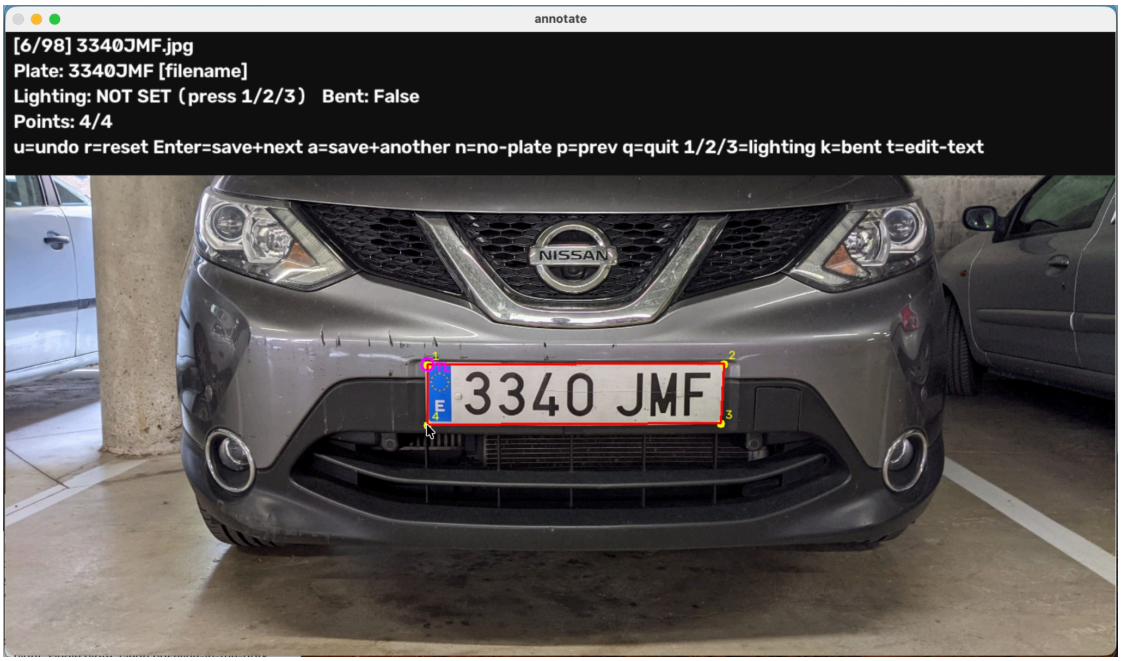

Com hem entrenat:
Hem reentrenat els dos models (LP-detection.pt i yolov8n.pt) amb la mateixa configuració, 100 epochs i imatges de 640 px:

- **dades d'entrenament**: el train de cv (48 fotos), own (31 fotos, 38 matrícules) i rata (96 fotos).
- **dades de validació**: cv (11), own (7 fotos, 8 matrícules) i rata (21). En total, 39 fotos per triar la millor epoch.

model de partida	epochs	millor epoch	precisió	recall	mAP50	mAP50-95
yolov8n	100	89	0,975	0,970	0,992	0,867
LP-detection	100	78	0,947	0,950	0,967	0,824

Les pèrdues que fem servir per mesurar com s'equivoca el model són:

- **box_loss**: com d'ajustada està la caixa.
- **cls_loss**: si encerta la classe.
- **dfl_loss**: la precisió de les vores de la caixa.

Les mètriques de detecció que fem servir:

- **mAP50** compta una detecció com a bona si la caixa coincideix almenys un 50% amb la matrícula.
- **mAP50-95** és més exigent: premia les caixes ben ajustades.
- **precision** → % de caixes que són una matrícula de veritat
- i **recall** → % de matrícules trobades (alguna caixa amb IoU ≥ 0,5)

Tots dos models troben gairebé totes les matrícules de validació (mAP50 0,97–0,99). La diferència és en l'ajust de la caixa: yolov8n ajusta millor (mAP50-95 0,867 contra 0,824). És el que fem servir a partir d'ara.

Pèrdua de train i val del millor model:

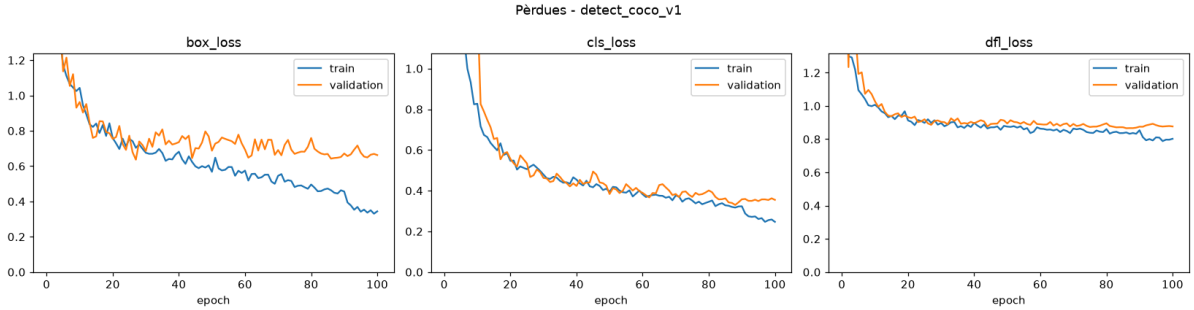

Les pèrdues de train i de validació baixen juntes fins a l'epoch ~25. Després, la de train continua baixant i la de validació s'estanca al voltant de 0,7 (box_loss), una mica per sobre del mínim (0,64). Vol dir que el model comença a memoritzar les fotos d'entrenament. Tot i així, el mAP50-95 de validació encara millora una mica fins a l'epoch 89, que és el que es desa com a millor model. A les últimes 10 epochs YOLO deixa de fer l'augmentació mosaic (combinar 4 fotos en una), i la pèrdua de train baixa de cop (box_loss de 0,46 a 0,38).

mAP50-95 dels dos entrenaments:

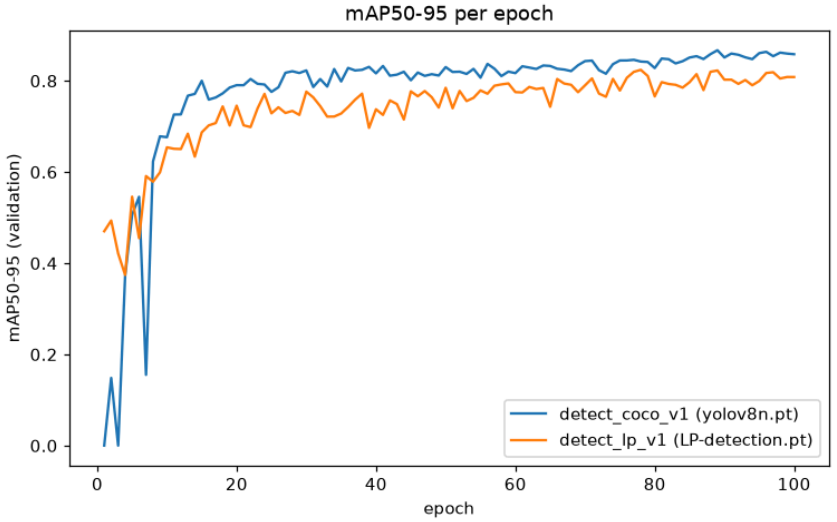

yolov8n ajusta millor les caixes que LP-detection a partir de l'epoch ~10, i des de l'epoch ~60 gairebé no millora (0,83 a l'epoch 50 i 0,867 a la 89).

b) Compara el rendiment del model YOLO ajustat i el de l'enfocament d'aprenentatge automàtic (ML) sota diferents condicions d'adquisició, utilitzant diverses mètriques de detecció.

Hem comparat 4 detectors amb les mateixes fotos:

- el detector clàssic dels professors (ML);
- LP-detection sense reentrenar;
- els dos models reentrenats (LP-detection i yolov8n, 100 epochs).

Els avaluem a les fotos de validació, que no s'han fet servir per entrenar però sí per triar el millor epoch. El test el reservem per avaluar el sistema final un sol cop. Una matrícula es dona per trobada si alguna caixa la cobreix amb IoU ≥ 0,5. Fem servir el recall, la precisió i la IoU mitjana de les matrícules trobades (com d'ajustada és la caixa).

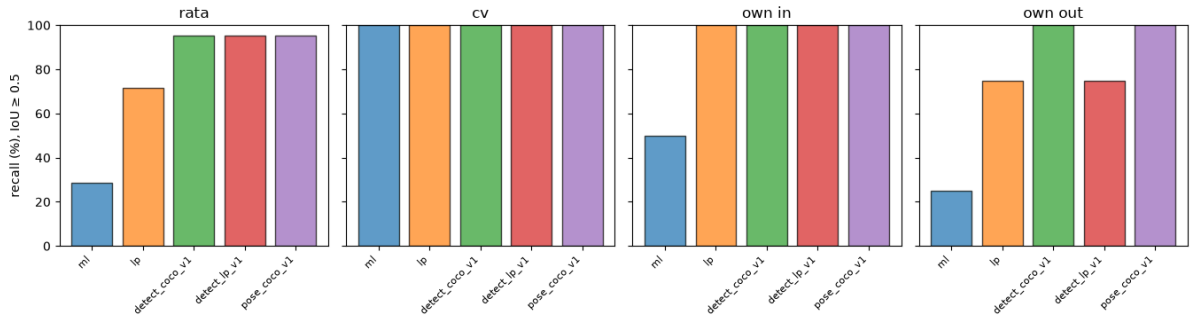

recall	cv val (11)	own in val (4)	own out val (4)	rata val (21)
ML (professors)	100 %	50 %	25 %	28,6 %
LP-detection preentrenat	100 %	100 %	75 %	71,4 %
LP-detection reentrenat	100 %	100 %	75 %	95,2 %
yolov8n reentrenat	100 %	100 %	100 %	95,2 %

Dins del protocol, a cv, tots dos enfocaments funcionen. El detector clàssic troba les 11 matrícules sense cap caixa falsa: els seus paràmetres (mida dels nuclis, proporció, àrea) estan pensats per a aquest tipus de foto.

Fora d'aquestes condicions, el detector clàssic falla i YOLO reentrenat no:

- a rata, el detector clàssic troba el 28,6 % de les matrícules i yolov8n reentrenat el 95,2 %;
- a own el detector clàssic baixa al 50 % (dins de protocol) i al 25 % (fora de protocol), mentre que yolov8n reentrenat les troba totes.

Les fotos own de validació són poques (4 dins i 3 fora de protocol), així que aquests percentatges són orientatius. Per això ja no fem la taula per condició (nit, lluny, angle…): cada condició tindria 1 o 2 matrícules.

Reentrenar és el que marca la diferència. LP-detection sense reentrenar ja és millor que el detector clàssic fora del protocol, però entrenat amb les nostres fotos passa del 71 % al 95 % a rata.

Altres mètriques que també hem calculat:

- **ajust de la caixa**: les caixes de YOLO reentrenat s'ajusten més a la matrícula (IoU mitjana 0,94 a cv i 0,91 a rata) que les del detector clàssic (0,87 i 0,83).
- **precisió**: YOLO reentrenat dona alguna caixa de més (1,1 per foto a cv, 1,5–2 a own), i la precisió baixa (91,7 % a cv i 66,7 % a own amb yolov8n). A own, part d'aquestes caixes «falses» són matrícules de cotxes del fons que no vam anotar. A rata, en canvi, és del 100 %.

El model final és yolov8n reentrenat 100 epochs, triat amb la validació (mAP50-95). Per al nostre ús importa més el recall: a cada foto ens quedarem la caixa amb més confiança, i una caixa de més es pot descartar, però una matrícula perduda no es pot recuperar.