OBJECTIU

• Mètodes d'aprenentatge automàtic (ML) per a la classificació d'imatges
• Familiaritzar-se amb els descriptors d'imatges: filtres convolucionals, patrons binaris locals (LBP), histogrames de gradients orientats (HOG)
• Visualització d'espais de característiques i exploració de les seves capacitats discriminatives
• Implementar un mètode per al reconeixement de caràcters de plaques

Exercici 1. Descriptor bàsic de la mitjana de blocs. Carregueu les fonts de dígits i caràcters plates i executeu el codi d'extracció de característiques de l'script CharacterDescriptors_Example.py.

*No disposàvem de les fonts (example_fonts.zip). Fem servir caràcters reals: els retalls de la nostra segmentació sobre les matrícules de train de cv, own i rata (1.141 caràcters: 336 de cv, 266 d'own i 539 de rata). L'etiqueta de cada caràcter surt del text anotat de la matrícula. No les hem revisat una a una.

a) Analitzeu els passos i paràmetres principals de la classe FeatureBlockBinaryPixelSum. Per què creieu que es canvia la mida de les imatges? CONSELL: Calculeu el descriptor amb i sense canvi de mida de la imatge i compareu la dimensionalitat dels descriptors entre imatges

FeatureBlockBinaryPixelSum redimensiona el caràcter a targetSize = 30 × 15 px (alt × ample), el divideix en blocs de 5 × 5 (blockSizes) i, a cada bloc, calcula la fracció de píxels diferents de zero. El descriptor és la llista d'aquestes fraccions: una versió del caràcter a molt baixa resolució (6 × 3 blocs).

Es redimensiona perquè tots els descriptors tinguin la mateixa dimensió. Sense resize, cada retall té una mida diferent i dona un nombre de blocs diferent; un classificador necessita vectors de la mateixa llargada.

	Dimensió
Amb resize a 30 x 15	18 (totes iguals)
Sense resize	de 6 a 247 (49 valors diferents en 1.141 imatges)

El descriptor compta píxels diferents de zero, i per tant espera una imatge binària. En grisos, gairebé cap píxel és zero: el valor mitjà del descriptor és 1,000 i no distingeix res. Per això binaritzem abans (Otsu invertit, caràcter en blanc). El valor mitjà baixa llavors a 0,404.

b) Quin paràmetre determina la dimensionalitat del descriptor?

La dimensionalitat la fixen targetSize i blockSizes. Per a cada mida de bloc, dimensió = (alçada / alçada del bloc) × (amplada/ amplada del bloc), i es sumen totes les mides de bloc.

targetSize	Blocs (ample x alt)	Dimensió
30 x 15	5 x 5	18
30 x 15	5 x 10	9
30 x 15	10 x 5	12
30 x 15	10 x 10	6
30 x 15	els quatre junts	45

60 x 30	5 x 5	72

c) Implementeu el descriptor de blocs mitjançant una convolució amb stride.

Convolem la imatge redimensionada amb un nucli de 5 × 5 ple de 1/25: cada punt és la mitjana del bloc de 5 × 5 que comença en aquell punt. Amb un stride de 5 en cada direcció ens quedem un punt per bloc, sense solapament. El resultat coincideix amb el descriptor dels profes: la diferència màxima és de $2{,}22 \cdot 10^{-16}$ en els 1.141 caràcters, és a dir, error d'arrodoniment.



Exercici 2. Descriptor HOG. Calculeu HOG sobre els dígits i les fonts de caràcters:

a) Utilitzeu el mètode extract_pixel_features de la classe FeatureHOG per calcular imatges HOG i visualitzar-les (vegeu la Figura 1 per a un exemple) per a un conjunt complet de dígits (0, .., 9) utilitzant diferents mides de cel·la. CONSELL: Ompliu les imatges amb 5 píxels a cada costat i redimensioneu-les per duplicar la mida original

Hem calculat les imatges HOG d'un exemple real de cada dígit (marge de 5 px i el doble de mida) amb cel·les de 4, 8 i 16 px. A aquesta mida, el traç fa 15,3 px de gruix (mediana).

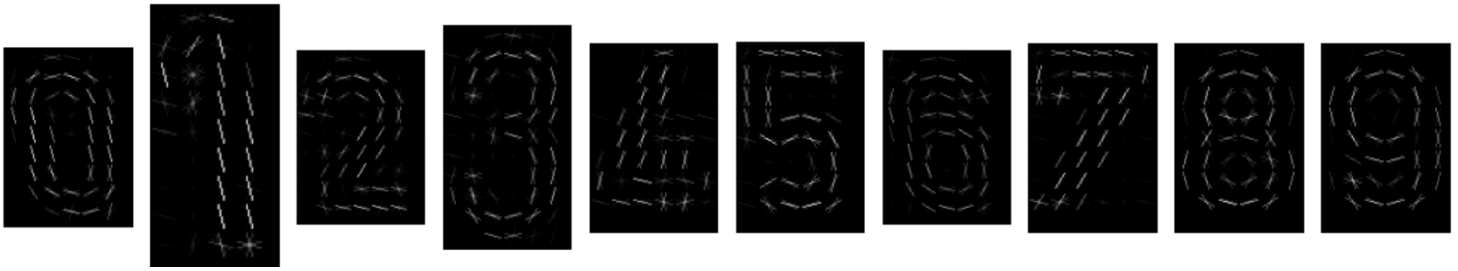
La cel·la 4x4 és molt més petita que el traç. Cada cel·la només veu una vora, i la imatge HOG dibuixa el contorn del caràcter amb doble línia (les dues vores de cada traç). Té molt de detall, però també és molt sensible al soroll.



La cel·la de 8x8 es continua veient la forma del dígit i cada cel·la ja indica la direcció de traç.



La cel·la de 16x16 té la mida del traç. Cada cel·la resumeix un tros de traç amb una direcció dominant. Als revolts i a les unions (2, 3, 8) apareixen "estrelles", perquè una sola cel·la hi barreja diverses direccions.



b) Quina és la relació entre les imatges HOG i el descriptor HOG? Defineix un criteri per triar la mida de cel·la per a l'HOG que s'introdueix a un classificador de dígits per al reconeixement de plaques.

La imatge HOG és el dibuix del descriptor. A cada cel·la hi ha l'histograma de les 8 orientacions del gradient: cada ratlla és una orientació, i com més brillant, més pes té. El descriptor és el mateix conjunt d'histogrames, normalitzats per blocs de 2 × 2 cel·les (L2-Hys) i posats en fila. Com que una cel·la entra a diversos blocs, el descriptor és més llarg que el nombre de cel·les × 8.
La cel·la ha de fer més o menys el gruix del traç, de manera que cada cel·la vegi un tros de traç amb les seves dues vores i en doni la direcció. A més, hi ha d'haver prou cel·les per conservar la disposició del caràcter.

A 64 × 32 (la mida fixa que fem servir a c), el traç fa 7,4 px:

Cel·la	Cel·les per caràcter (54x32)	Dimensió
4 x 4	16 x 8	3360
8 x 8	8 x 4	672
16 x 16	4 x 2	96

Triem 8 × 8: és la mida més propera al gruix del traç i encara deixa 8 × 4 cel·les. La de 4 només veu vores. La de 16 deixa només 4 × 2 cel·les, massa poques per distingir caràcters semblants. La tria es fa només amb train. (A l'Ex4 d veurem que, amb aquestes dades, la mida de cel·la gairebé no canvia l'encert.

c) Calcula el descriptor HOG per a tot el conjunt de dades de dígits i calcula la seva dimensionalitat. Per què creieu que varia entre imatges? Proposa una solució per tenir un espai de característiques vàlid per a un problema de classificació.

Sense redimensionar, la dimensió varia d'una imatge a una altra:

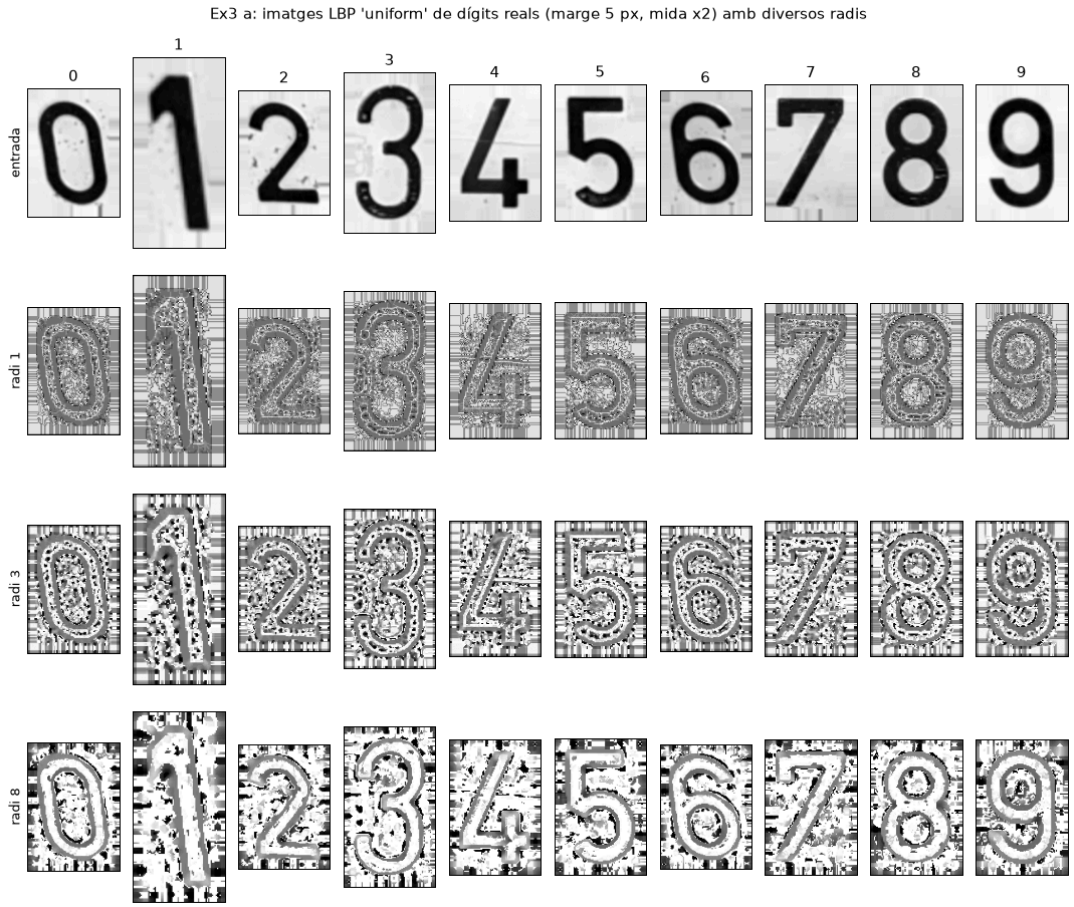
Cel·la	Sense redimensionar	A 64 x 32
4 x 4	64-9856 (62 valors diferents)	3360
8 x 8	64-1920 (25)	672
16 x 16	32-256 (6)	96

Varia perquè el nombre de cel·les (i de blocs) depèn de la mida de la imatge, i els retalls reals tenen mides diferents. La solució és la mateixa que a l'Ex1: redimensionar tots els caràcters a una mida fixa abans de calcular HOG. Fem servir 64 × 32, amb la mateixa proporció 2:1 que el 30 × 15 de l'Ex1. Així, amb la cel·la de 8, tots els descriptors tenen 672 dimensions.

Exercici 3. Descriptor LBP. Càlcul de l'LBP sobre dígits i tipus de lletra

a) Utilitzeu el mètode `extract_pixel_features` de la classe `FeatureLBP` per calcular imatges LBP i visualitzar-les (vegeu la Figura 2 per a un exemple) per a tot el conjunt de dígits (0, ..., 9) utilitzant diferents radis. PISTA: Afegiu un marge de 5 píxels a cada costat de les imatges i redimensioneu-les al doble de la mida original.

Hem calculat les imatges LBP (extract_pixel_features, variant uniform) de train, amb un marge de 5 px i el doble de mida, com indica la pista. Hem fet servir els radis 1, 3 i 8. No disposàvem de les fonts, i per això fem servir caràcters reals.



b) Quin és l'impacte del radi? Com es calcula el descriptor LBP a partir de la imatge LBP?

LBP compara cada píxel amb 8·r veïns d'un cercle de radi r i en fa un codi que descriu el patró local: vora, cantonada, zona plana… A la mida de la figura, el traç fa uns 15 px.

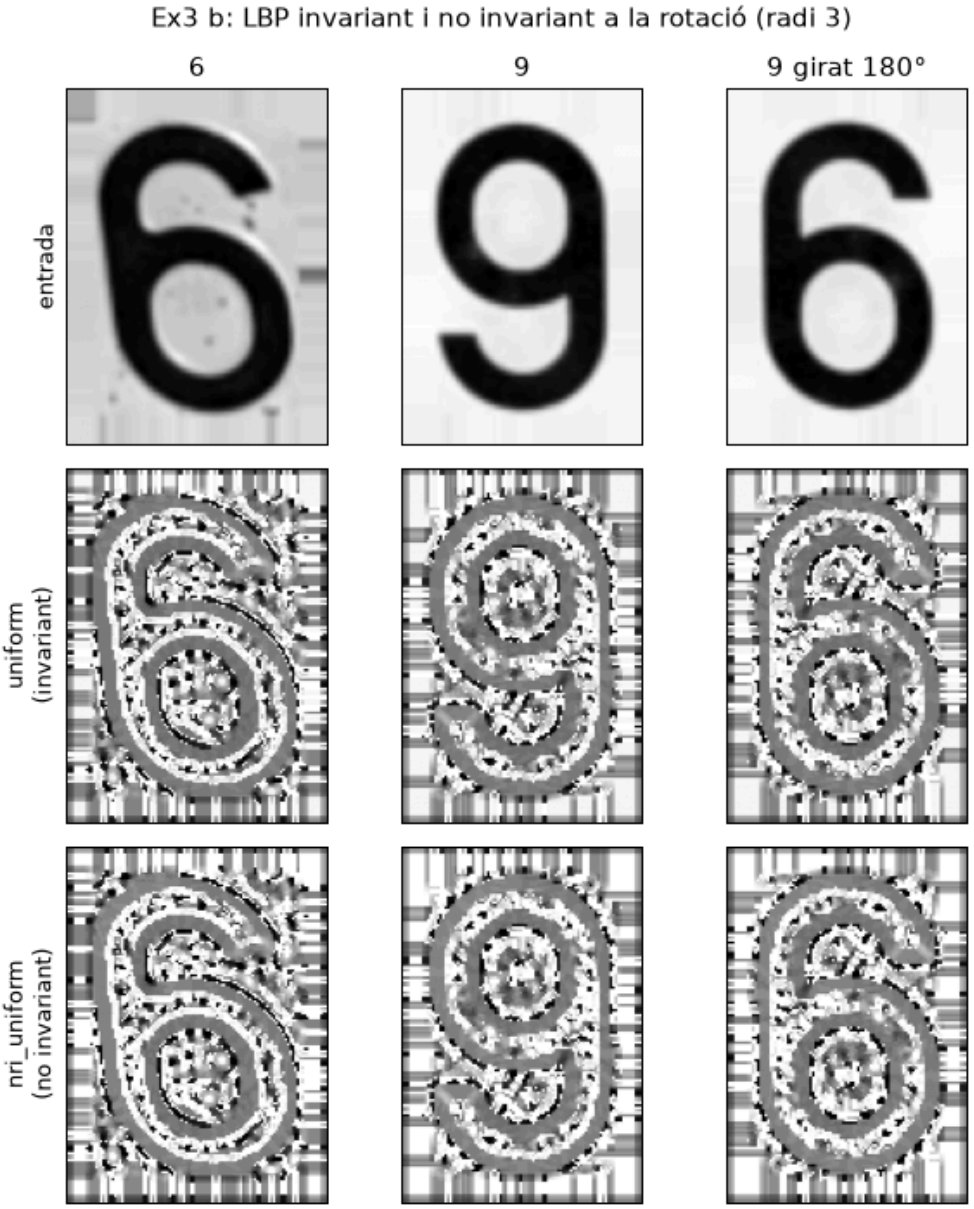
- Radi 1: compara píxels gairebé enganxats. Veu la textura fina: el soroll del fons i la brutícia de la matrícula surten per tot arreu, i el traç queda dibuixat com un contorn prim.
- Radi 3: el contorn del caràcter queda marcat com una banda clara i contínua. El fons continua sortint sorollós.
- Radi 8: compara píxels separats per mig traç. Els patrons descriuen estructures més grans (el traç sencer) i les bandes del contorn s'eixamplen, però el fons forma taques grans.

El descriptor es calcula a partir de la imatge LBP fent l'histograma dels codis. Pot ser un sol histograma per a tota la imatge (simple) o un histograma per a cada bloc d'una graella, tots posats en fila (block_lbp). Cada histograma es normalitza (L2).

c) Compareu les imatges LBP calculades mitjançant un mètode invariant a la rotació i un altre que no ho és, per a dígits amb orientacions diferents. Compareu les imatges LBP dels dígits 9 i 6. Què significa la invariància a la rotació?

Un LBP invariant a la rotació (uniform) dona el mateix codi a un patró encara que giri: una vora vertical i una d'horitzontal tenen el mateix codi. El no invariant (nri_uniform) els distingeix.

Hem comparat un 6, un 9 i el mateix 9 girat 180°. La imatge LBP del 9 girat és la del 9 girada, i s'assembla a la del 6, amb tots dos mètodes. La imatge LBP mai no és invariant, perquè cada codi continua al seu lloc. La invariància a la rotació és dels codis: el patró local té el mateix codi encara que giri.



d) Calculeu el descriptor LBP a partir d'un patró uniforme utilitzant un histograma per blocs per als dígits 9 i 6. Projecteu els descriptors en un espai bidimensional per a la seva visualització. És el descriptor invariant a la rotació? Per què? És invariant si utilitzem una agregació d'histograma global (mida de bloc 1x1)? Necessitem descriptors invariants a la rotació per al problema de classificació de dígits?

Hem fet servir els 53 sisos i 61 nous de train, i els mateixos nous girats 180°, tots a 64 × 32 i amb radi 3:

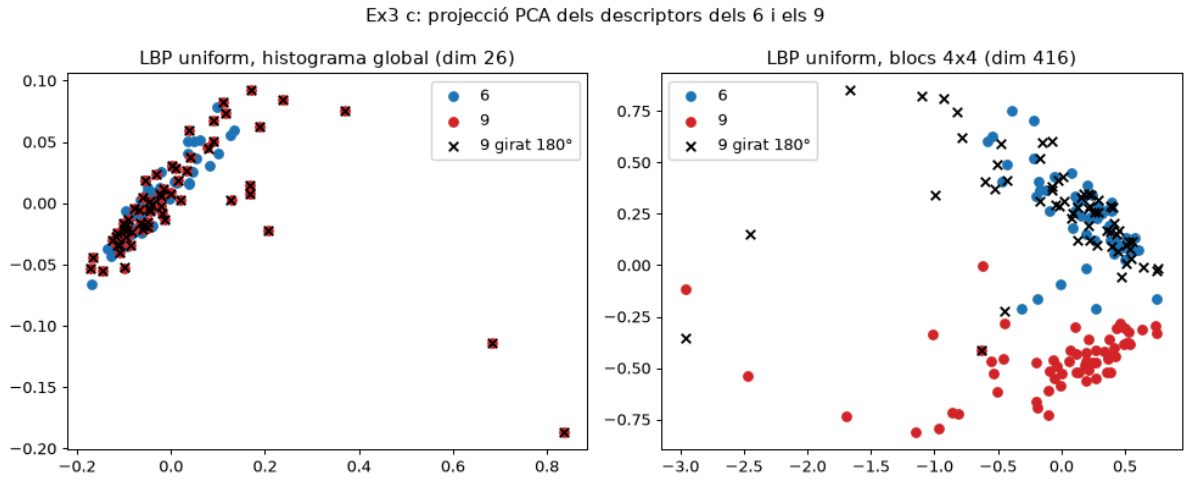
Descriptor	Dim.	9 vs el seu 9 girat	6 vs 9	6 vs 9 girat
Blocs 4 x 4	416	1,379	1,523	1,336
Histograma global (bloc 1x1)	26	0,001	0,161	0,161

(Distància euclidiana mitjana.)

Per blocs, no és invariant. Girar un 9 en canvia el descriptor tant com passar d'un 6 a un 9 (1,379 contra 1,523), perquè els codis canvien de bloc. Un 9 girat queda més a prop dels 6 (1,336). A la projecció PCA, els 9 queden separats i els 9 girats es barregen amb els 6.

Amb l'histograma global, sí que és invariant. Girar un 9 gairebé no canvia el descriptor (0,001), perquè els codis no canvien i l'histograma no guarda on és cada codi. A la PCA, cada 9 girat cau damunt del seu 9, i els 6 i els 9 queden barrejats.

No necessitem invariància a la rotació, les matrícules arriben redreçades, i un 6 i un 9 només es distingeixen per l'orientació. La invariància ens fa perdre informació útil.



e) Compareu els descriptors LBP calculats utilitzant les dues agregacions d'imatges LBP: histograma global (`lbp_type='simple'`) i concatenació d'histogrames per blocs (`lbp_type='block_lbp'`). Compareu la dimensionalitat d'ambdós descriptors en funció de la mida de la imatge d'entrada. Quin té una dimensionalitat fixa? Per què?

Amb els retalls sense redimensionar (alçades de 7 a 75 px), tots dos descriptors tenen dimensió fixa:

Global (simple): 26. El nombre de classes de l'histograma depèn només del radi: radi 3 → 24 punts + 2 = 26.
Per blocs (block_lbp): 416 = 16 blocs × 26. També és fixa amb el codi dels profes, perquè block_lbp divideix la imatge en una graella fixa de 4 × 4 que s'adapta a la mida, no en blocs d'una mida fixa en píxels.

Si els blocs tinguessin una mida fixa en píxels, com a l'Ex1 sense resize, el nombre de blocs (i per tant la dimensió) dependria de la mida de la imatge.

f) Proposeu una solució perquè l'agregació per blocs defineixi un espai de característiques vàlid per a un problema de classificació.

Hi ha dues opcions: fer servir una graella fixa de blocs (com fa el codi dels profes) o redimensionar abans tots els caràcters a una mida fixa. Nosaltres fem les dues coses: 64 × 32 i una graella de 4 × 4, és a dir, blocs de 16 × 8 px. Així, cada bloc correspon sempre a la mateixa part del caràcter, i caràcters de mides diferents són comparables bloc a bloc.

Exercici 4. Visualització i exploració d'espais de característiques. Modifiqueu l'script `CharacterDescriptors_Example.py` per tal de calcular i comparar els diferents descriptors d'imatge aplicats als dígits i als tipus de lletra.

a) Calculeu els descriptors Block Average, HOG i LBP, utilitzant tant l'agregació global com la basada en blocs, sobre el conjunt de dades complet de dígits i caràcters.

Hem calculat els quatre descriptors per a tots els caràcters de train de cv, own i rata: 652 dígits i 489 lletres de 102 vehicles. Les fonts no eren disponibles, i per això fem servir caràcters reals. Els paràmetres són els justificats a les Ex1–3:

- Block Average: binaritzat, 30 × 15, blocs de 5 × 5 (dim. 18).
- HOG: 64 × 32, cel·la de 8 × 8 (dim. 672).
- LBP uniform amb radi 3: histograma global (dim. 26) i per blocs 4 × 4 (dim. 416).

Dígits i lletres es tracten per separat, perquè una matrícula sempre té 4 dígits seguits de 3 lletres. Hem reescrit els descriptors en un mòdul propi, que dona exactament el mateix que les classes dels profes (diferència 0).

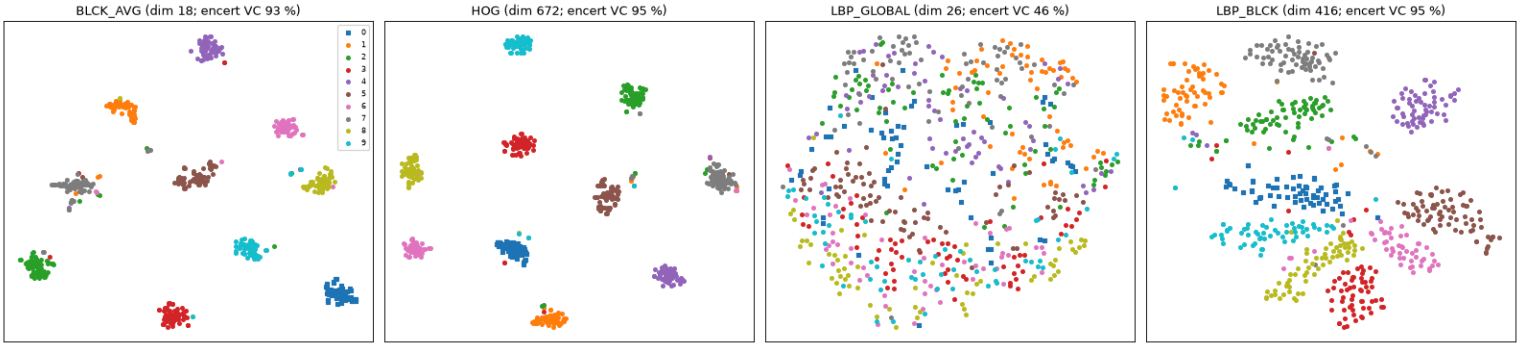
b) Per a cada extractor de característiques, utilitzeu la projecció t-SNE per visualitzar els espais de característiques de cada dígit/caràcter en un mateix gràfic, tal com es mostra a la Figura 3. Analitzeu-ne el poder discriminatiu.

A més del t-SNE, mesurem el poder discriminatiu amb l'encert d'un classificador lineal (SVM lineal) de dues maneres:

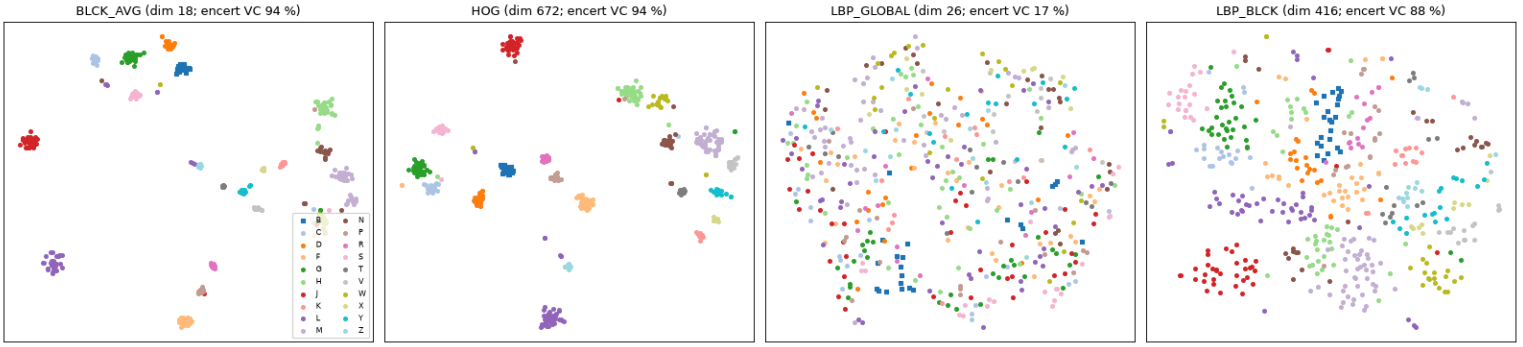
- validació creuada de 5 particions a train, agrupada per vehicle (un mateix cotxe no és mai alhora a entrenar i a provar);
- entrenant amb train i provant amb validation.

Descriptor	Dim.	Dígits: VC train	Dígits: validation	Lletres; VC train	Lletres: validation
Block Average	18	93,3%	94,4%	93,7%	93,3%
HOG	672	94,8%	95,6%	94,3%	97,5%
LBP global	26	46,0%	43,1%	17,4%	14,2%
LBP per blocs	416	95,1%	95,6%	87,7%	93,3%

Als dígits, HOG, Block Average i LBP per blocs encerten tots entre el 93 % i el 95 %. Al t-SNE, HOG i Block Average formen grups compactes i separats, un per dígit. LBP per blocs també separa els dígits, però els grups són més difusos. LBP global no mostra cap estructura.



Les lletres són més difícils (20 classes, algunes amb només 11–15 exemples, com X, T, Z i K). HOG és el millor (94,3 % a la VC, 97,5 % a validation), Block Average queda molt a prop, i LBP per blocs baixa al 87,7 %.



Validation té 160 dígits i 120 lletres: cada error hi resta menys d'1 punt.

c) Per què l'LBP amb agregació d'histograma global sembla tenir el menor poder discriminatiu? Quins dígits es confonen? Per què creieu que passa això (PISTA: Analitzeu les imatges LBP)? Per què l'LBP calculat per blocs supera aquesta limitació?

L'histograma global compta quants patrons de cada tipus hi ha (vores, cantonades, puntes, zones planes), però perd on són. Tots els caràcters estan fets amb el mateix traç i la mateixa tipografia, i per això tenen una barreja de patrons semblant. A les imatges LBP de l'Ex3 es veu: tots els dígits donen la mateixa banda de codis al llarg del contorn i el mateix soroll al fons, i només canvia el recorregut de la banda. A més, els codis uniform són invariants a la rotació: una vora vertical i una de diagonal donen el mateix codi.

Els parells de dígits que més es confonen (errors en tots dos sentits, a la validació creuada) són: 3-5 (33), 2-7 (33), 8-9 (32), 4-7 (31) i 6-8 (29).

- 3, 5, 6, 8 i 9 estan fets sobretot de traços corbs, i tenen una proporció semblant de vores corbes. Només els diferencia on hi ha cada corba.
- 2, 4 i 7 tenen traços rectes i diagonals, que donen els mateixos codis.

LBP per blocs supera aquesta limitació perquè fa un histograma per a cada una de les 16 zones del caràcter: guarda quins patrons hi ha i també on són, és a dir, la forma. Passa del 46,0 % al 95,1 % als dígits. A les lletres es queda per sota de HOG (87,7 % contra 94,3 %) perquè, dins de cada bloc, els codis uniform no diuen la direcció de la vora.

d) Visualitzeu els descriptors utilitzant diversos paràmetres i determineu-ne els valors heurístics òptims.

Hem provat diversos paràmetres per a cada descriptor. Per triar-los hem fixat un criteri abans de veure els resultats: la combinació amb més encert mitjà (dígits i lletres) a la validació creuada de train, i, si dues queden a menys d'1 punt, la de menys dimensions. Validation no intervé en la tria.

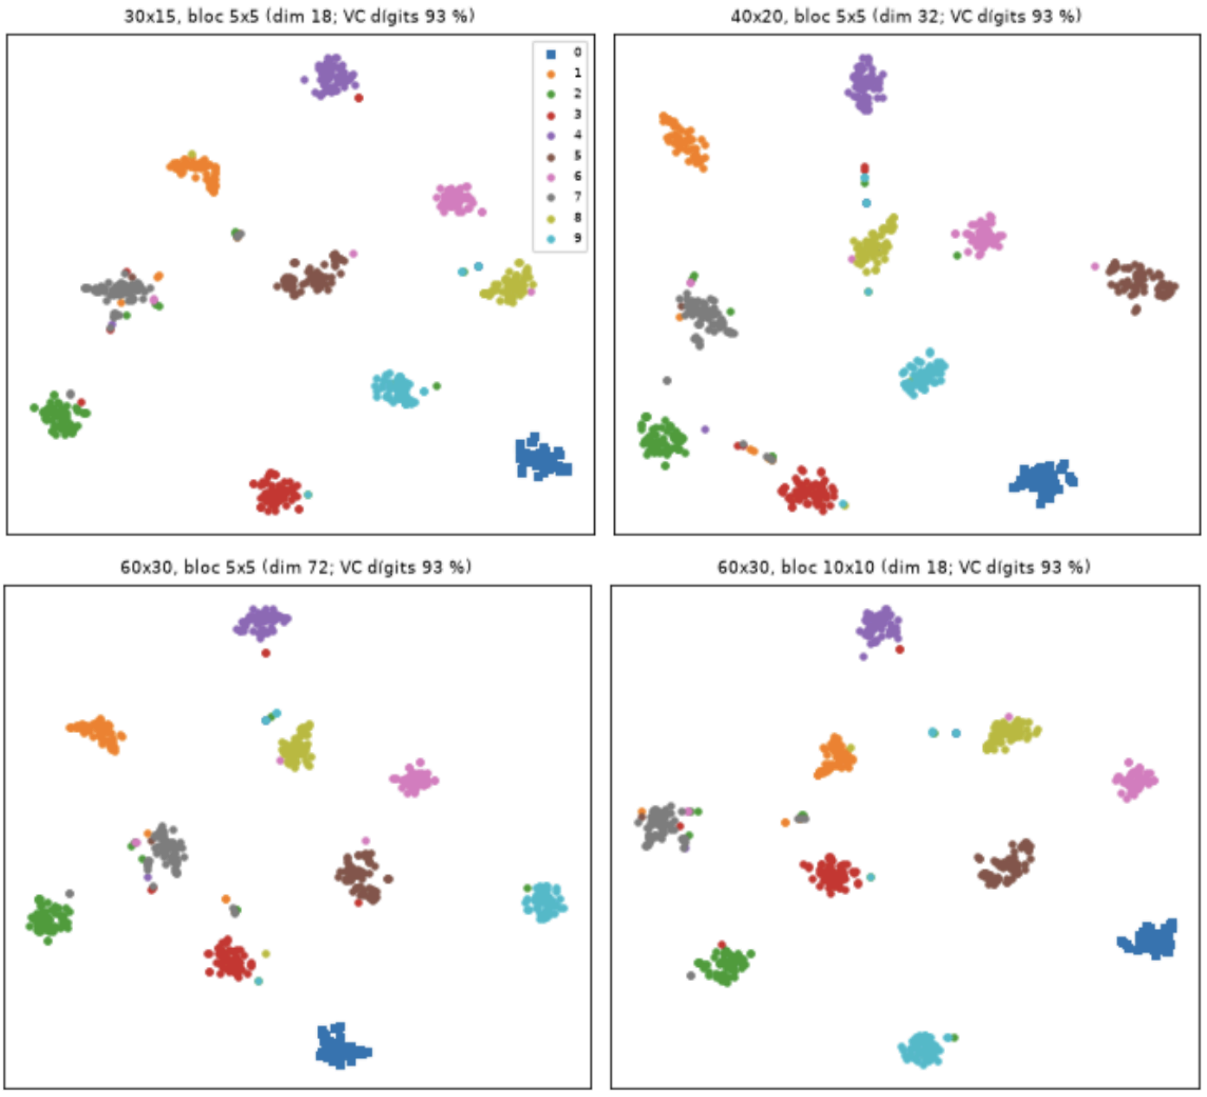
Descriptor	Paràmetres	Dim.	VC dígits	VC lletres	VC mitjana
Block Average	**30 × 15, bloc 5 × 5**	**18**	**93,3 %**	**93,7 %**	**93,5 %**
	40 × 20, bloc 5 × 5	32	93,4 %	93,5 %	93,4 %
	60 × 30, bloc 5 × 5	72	92,9 %	94,1 %	93,5 %
	60 × 30, bloc 10 × 10	18	93,4 %	94,1 %	93,7 %
HOG	cel·la 4	3.360	94,3 %	93,9 %	94,1 %
	cel·la 8	672	94,8 %	94,3 %	94,5 %
	cel·la 16	**96**	**94,3 %**	**92,8 %**	**93,6 %**
LBP global	radi 1	10	25,6 %	16,4 %	21,0 %
	radi 2	18	38,8 %	17,6 %	28,2 %
	radi 3	**26**	**46,0 %**	**17,4 %**	**31,7 %**
	radi 8	66	36,3 %	19,2 %	27,8 %
LBP per blocs	uniform radi 1	160	81,9 %	72,6 %	77,2 %
	uniform radi 2	288	92,5 %	83,4 %	88,0 %
	uniform radi 3	416	95,1 %	87,7 %	91,4 %
	nri_uniform radi 1	**944**	**94,6 %**	**93,5 %**	**94,0 %**
	nri_uniform radi 2	3.888	94,3 %	93,5 %	93,9 %

(En negreta, la combinació triada per a cada descriptor.)

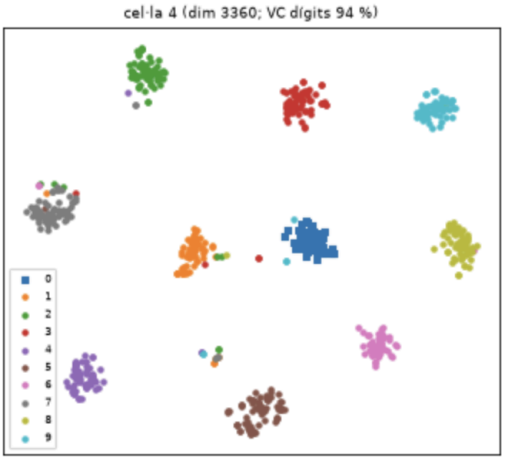
- Block Average: totes les combinacions queden a menys de 0,3 punts. Amb més dades, més resolució ja no ajuda, i triem la més petita: 30 × 15 amb blocs de 5 × 5 (dim. 18).
- HOG: totes les cel·les queden a menys d'1 punt (93,6–94,5 %), i el criteri tria la de menys dimensions, la de 16 (dim. 96). A l'Ex2 havíem proposat la cel·la de 8 pel gruix del traç. És la que té més encert, però per menys d'1 punt. Amb aquestes dades, la mida de la cel·la gairebé no importa.
- LBP global: cap radi no el salva; el problema és l'agregació, no el radi.
- LBP per blocs: el no invariant (nri_uniform) supera clarament l'uniform (94,0 % contra 91,4 %), sobretot a les lletres (93,5 % contra 87,7 %). Confirma que la invariància a la rotació fa perdre informació útil per reconèixer caràcters. Hem corregit el nombre de classes de nri_uniform, que FeatureLBP comptava malament.

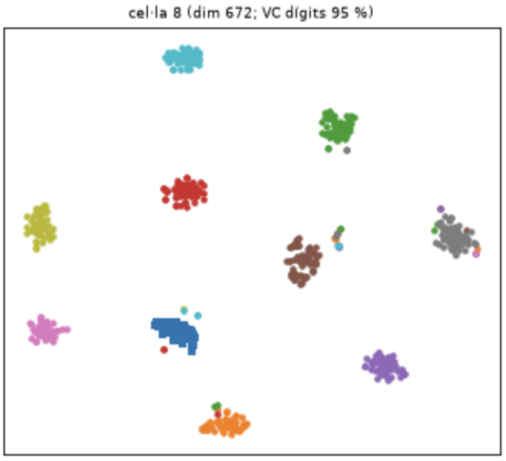
Als t-SNE es veu el mateix: HOG i Block Average formen grups compactes amb tots els paràmetres, LBP per blocs millora clarament amb nri_uniform, i LBP global no s'agrupa amb cap radi.

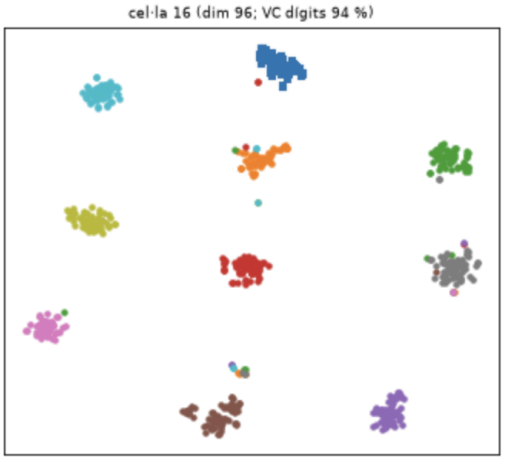
t-SNE de Block Average:



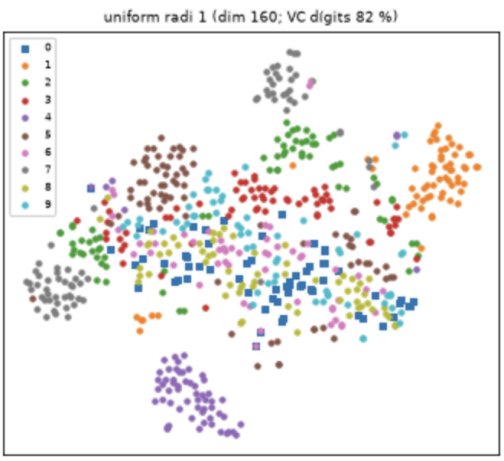
t-SNE de HOG:

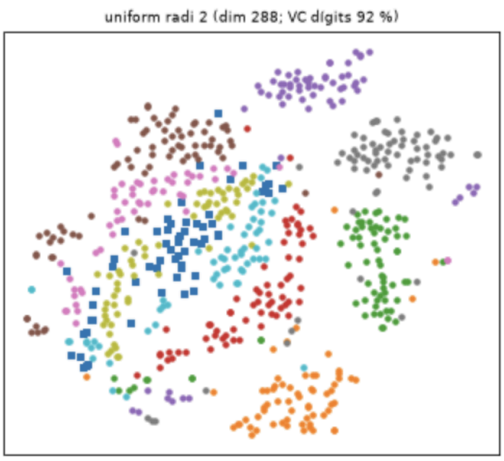


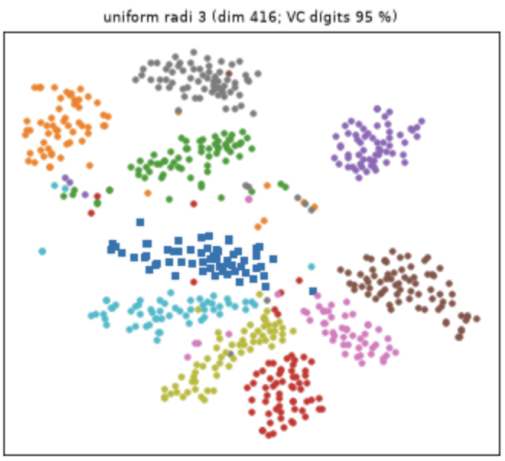


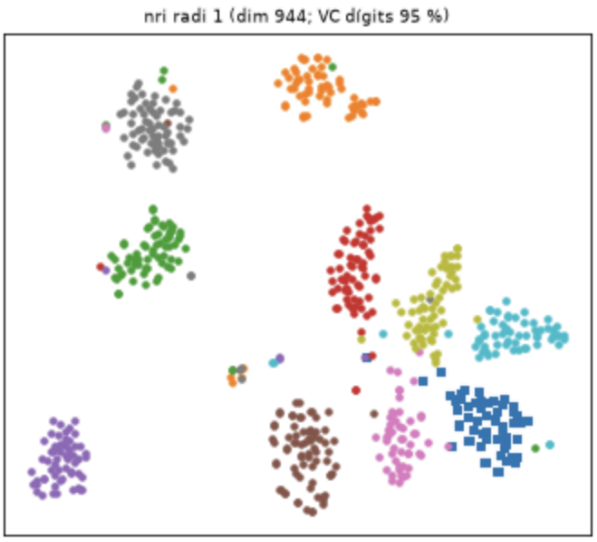


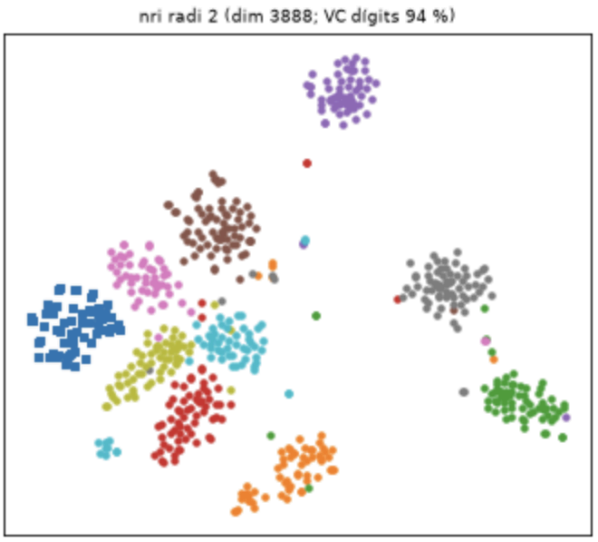
t-SNE de LBP global:



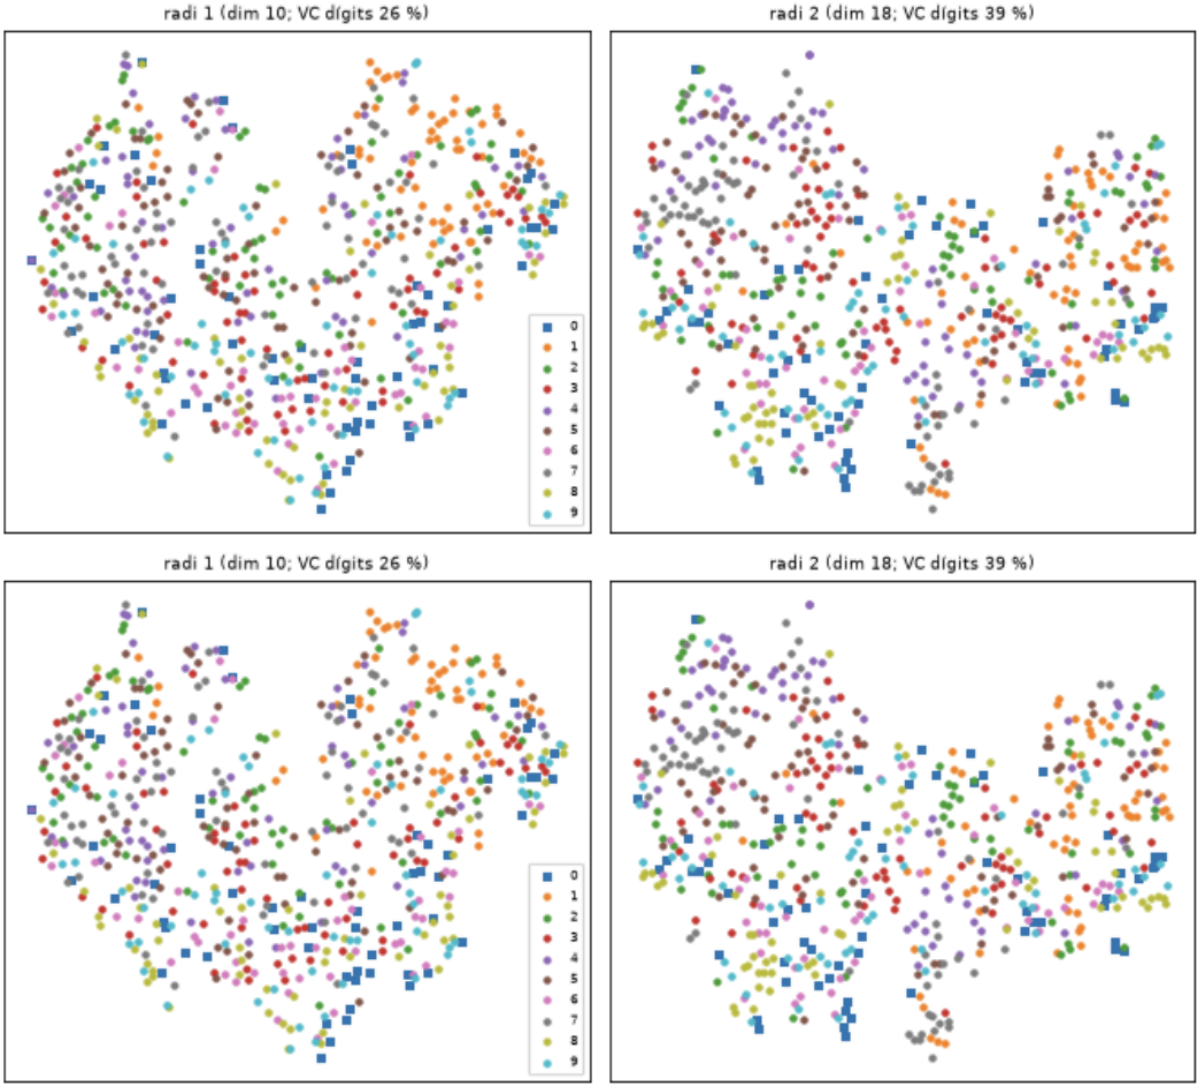








t-SNE de LBP per blocs:



Al sistema final, el classificador s'entrena amb els nostres caràcters de train i, a més, amb els caràcters d'uc3m (un dataset públic de matrícules amb els caràcters anotats). Amb uc3m, a la nostra validation l'encert és el mateix (96,4 %), però a la validation d'uc3m passa del 90,5 % al 96,3 %: generalitza millor a fotos diferents de les nostres.