OBJECTIU

• Fonaments de la necessitat d'una validació estadística
• Divisió de dades: *train-test* simple, *bootstrap*
• Introducció a l'informe i l'anàlisi de mètriques
• Estadística descriptiva
• Proves estadístiques simples: càlcul i interpretació dels resultats

Exercici 1. Avaluació bàsica. L'script `BootStrap_Assessment.py` conté un exemple senzill d'un problema de classificació binària utilitzant 3 classificadors diferents (SVM, KNN i MLP). S'utilitza una divisió aleatòria 80-20 per entrenar i provar els mètodes.

a) Posa a prova els 3 classificadors utilitzant una única divisió *train-test* (NTrial=1). Modifica l'script per incorporar les funcions de `sklearn.metrics`: `precision_score`, `recall_score`, `accuracy_score`. Compara els resultats de `precision_score`, `recall_score` i `accuracy_score` utilitzant les mitjanes "micro", "macro" i "weighted" per a la *recall* i la precisió.

	SVM	**KNN**	**MLP**
AUC	0,972	0,926	0,947
accuracy	0,92	0,908	0,908
precisió dígit (0) / lletra (1)	0,840 / 0,952	0,864 / 0,923	0,900 / 0,910
recall dígit (0) / lletra (1)	0,875 / 0,937	0,792 / 0,952	0,750 / 0,968
precisió micro / macro / weighted	0,920 / 0,896 / 0,921	0,908 / 0,893 / 0,907	0,908 / 0,905 / 0,908
recall micro / macro / weighted	0,920 / 0,906 / 0,920	0,908 / 0,872 / 0,908	0,908 / 0,859 / 0,908

micro suma tots els encerts i errors junts, sense mirar la classe. En un problema on cada exemple té una sola etiqueta, la precisió i el recall micro són iguals a l'accuracy, i per això surt el mateix número.
macro calcula la mètrica de cada classe i en fa la mitjana simple. Les dues classes pesen igual, encara que hi hagi menys dígits que lletres.
weighted fa la mitjana de les classes, però pesada pel nombre d'exemples de cada una. Com que les lletres són el 72 % del test, s'acosta molt a la micro.

Per això el recall macro és el més baix: és l'únic que “castiga” que els dígits, la classe petita, es reconeguin pitjor. A l'MLP es veu clar: té un recall micro de 0,908, però un recall macro de només 0,859, perquè troba el 97 % de les lletres i només el 75 % dels dígits.

b) Què retorna la funció `metrics.precision_recall_fscore_support`?
Calcula la *recall* i la precisió mitjanes a partir del seu resultat. Repeteix el procés per a NTrial=3.
Compara les puntuacions mitjanes amb les puntuacions per classe. Quina permet detectar biaixos en les prediccions?

La funcio precision_recall_fscore_suport retorna quatre vectors amb un valor per classe:

- la **precisió:** de tot el que he dit que és aquesta classe, quina part ho hes de veritat.
- el **recall:** de tots els exemples d'aquesta classe, quina part he trobat.
- l'**F1,** que combina la precisió i el recall (mitjana).
- el **suport,** que és el nombre d'exemples reals de cada classe (24 dígits i 63 lletres).

Si fem la mitjana simple dels dos valors de precisió i recall obtenim la versió macro (com es pot veure en la primera iteració):

prova	SVM (P / R)	KNN (P / R)	MLP (P / R)
0	0,896 / 0,906	0,893 / 0,872	0,905 / 0,859
1	0,833 / 0,814	0,743 / 0,715	0,886 / 0,817
2	0,924 / 0,901	0,846 / 0,734	0,915 / 0,880

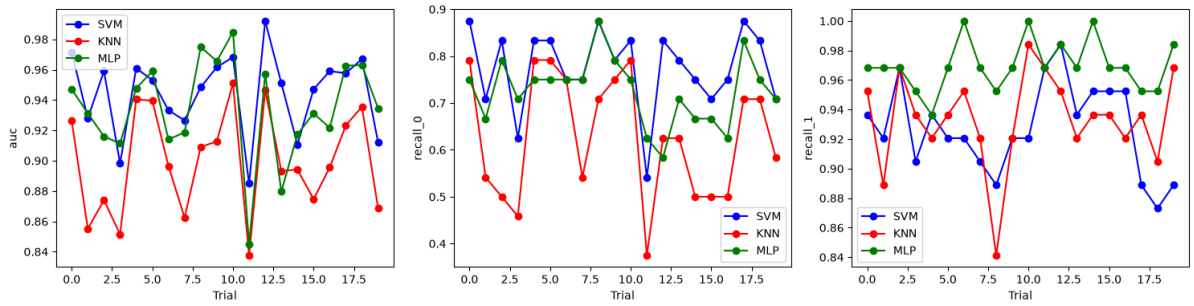
Les puntuacions fetes per la mitjana poden quedar altes encara que una classe vagi molt malament. Per exemple en la prova 2 el KNN (del següent exercici) té un recall de 0,968 a les lletres però només de 0,500 als dígits. La mitjana ho acaba amagant i la micro d'accuracy també.
Per tant la mètrica que permet detectar biaixos en les prediccions és la mètrica per classe.

c) Posa a prova els 3 classificadors utilitzant una única divisió *train-test* (NTrial=1). Quin classificador presenta mètriques de prova més elevades: AUC, *recall* per a cada classe (dígit 0, caràcter 1)? Repeteix-ho 5 vegades. Es mantenen les mateixes conclusions en les 5 proves?

prova	AUC (SVM / KNN / MLP)	recall dígit	recall lletra
0	0,972 / 0,926 / 0,947	0,875 / 0,792 / 0,750	0,937 / 0,952 / 0,968
1	0,928 / 0,855 / 0,931	0,708 / 0,542 / 0,667	0,921 / 0,889 / 0,968
2	0,959 / 0,874 / 0,916	0,833 / 0,500 / 0,792	0,968 / 0,968 / 0,968
3	0,898 / 0,852 / 0,911	0,625 / 0,458 / 0,708	0,905 / 0,937 / 0,952
4	0,961 / 0,940 / 0,948	0,833 / 0,792 / 0,750	0,937 / 0,921 / 0,937

A la primera iteració el classificador amb millor puntuació era és SVM. Si repetim les proves unes altres 4 vegades veiem que SVM guanya les proves 0, 2 i 4, en canvi les proves 1 i 3 les guanya l'MLP.
Amb una sola divisió no podem dir quin és el millor, perquè depèn de la sort de la partició. Per això cal repetir-ho moltes vegades, que és el que fa el bootstrap.

d) Entrena els classificadors per a NTrial=20 divisions aleatòries i visualitza les 3 mètriques, utilitzant el codi de visualització del PAS 2. ANALITZA ELS RESULTATS. Analitza les mètriques al llarg de les diferents divisions aleatòries. Mostren alguna tendència comuna? Quin classificador ofereix el millor rendiment?



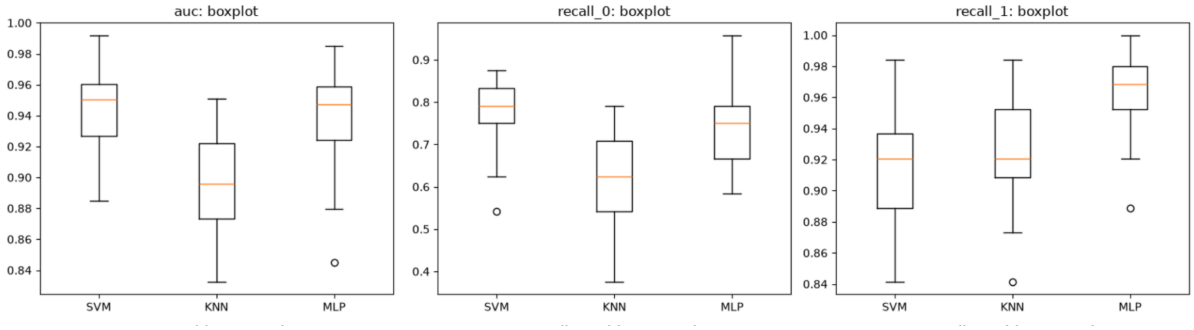
Tendències comunes: les tres corbes pugen i baixen alhora. Hi ha divisions "difícils" per a tots (la prova 11 per exemple). I n'hi ha de fàcils (com la 10 i la 12). Molta part de la variació ce de quins exemples cauen al test, no del classificador.

Millor rendiment: En mitjana l'SVM té el millor rendiment global (AUC 0,945 contra 0,934 de l'MLP i 0,899 del KNN) i és el que menys es descuida els dígits. L'MLP és el millor reconeixent lletres.

Exercici 2. Exploració del rendiment. Entrena els classificadors per a NTrial=30 divisions aleatòries utilitzant `BootStrap_Assessment.py`:

a) Utilitza diagrames de caixa (*boxplots*, com els que es mostren a la Figura 1), diagrames de barres i histogrames per comparar les mètriques dels 3 classificadors. Quin classificador creus que és el millor? Quin és el pitjor? Hi ha algun classificador amb un rendiment similar?

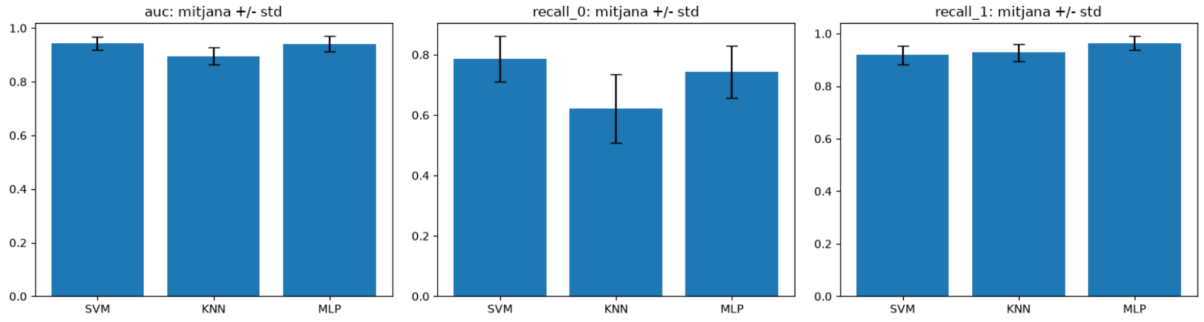
Boxplots:



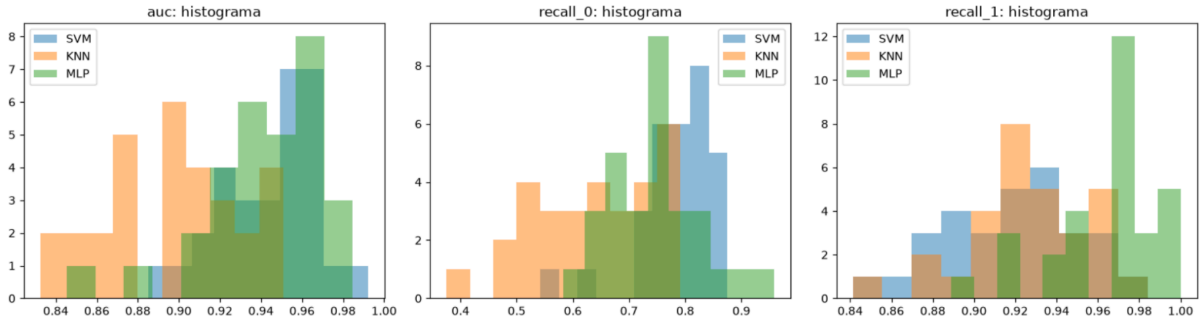
El pitjor és clarament el KNN. La seva caixa d'AUC és sencera per sota de les altres dues, i en recall de dígits té la mediana més baixa i la caixa més allargada (és el més irregular).

L'SVM i l'MLP tenen rendiment semblant en AUC. Les seves caixes són gairebé iguals i els histogrames (a baix) també.
L'SVM i l'MLP es diferencien perquè l'SVM és millor amb els dígits, i l'MLP és millor amb les lletres.

Barres amb mitjana ± desviació:



Histogrames:



b) Per a cada classificador, calcula estadístics descriptius (mitjana, mediana, desviació estàndard, quantils, màxim, mínim) que resumeixin les 3 mètriques al llarg dels *NTrials*. Quin classificador presenta unes mètriques mitjanes més elevades? Creus que això és suficient per descartar els altres classificadors?

Mètrica	model	mean	median	sd	mín	Q1	Q3	màx
AUC	SVM	0,944	0,950	0,024	0,885	0,927	0,960	0,992
	KNN	0,896	0,896	0,033	0,832	0,874	0,922	0,951
	MLP	0,941	0,947	0,029	0,845	0,924	0,959	0,985
recall dígit	SVM	0,786	0,792	0,076	0,542	0,750	0,833	0,875
	KNN	0,622	0,625	0,115	0,375	0,542	0,708	0,792
	MLP	0,743	0,750	0,088	0,583	0,667	0,792	0,958
recall lletra	SVM	0,919	0,921	0,036	0,841	0,889	0,937	0,984
	KNN	0,928	0,921	0,033	0,841	0,909	0,952	0,984
	MLP	0,963	0,968	0,027	0,889	0,952	0,980	1,000

L'SMV té les mètriques més altes en AUC i en recall de dígits, i l'MLP en recall de lletres. No n'hi ha prou per descartar els altres a que la diferència d'AUC entre l'SVM i l'MLP és de 0,003, i la desviació de cada un és de 0,024 - 0,029 (x10 vegades més gran). A més, els rangs mínim-màxim se superposen molt. Amb la mitjana sola no sabem si la diferència és real o és soroll de les particions. Per decidir-ho cal una prova estadística (Ex3).

c) Presenta els rangs de les mètriques en el format «mitjana ± desviació estàndard». Si haguessis de crear un classificador de conjunt (*ensemble*), quins classificadors utilitzaries?

Rangs en format mitjana ± desviació estàndard:

	AUC	**recall dígit**	**recall lletra**
SVM	0,944 ± 0,024	0,786 ± 0,076	0,919 ± 0,036
KNN	0,896 ± 0,033	0,622 ± 0,115	0,928 ± 0,033
MLP	0,941 ± 0,029	0,743 ± 0,088	0,963 ± 0,027

Si haguéssim de fer un ensamble combinaríem l'SVM i l'MLP perquè són forts en coses diferents: l'SVM en dígits i l'MLP en lletres. Un ensamble només millora si els models es complementen. El KNN no aportaria res ja que té AUC pitjor i no supera en dígits ni en lletres als altres dos.

Exercici 3. Avaluació mitjançant *bootstrap*. Entrena classificadors per a `NTrial=30` divisions aleatòries utilitzant `BootStrap_Assessment.py`.

a) Calcula els intervals de confiança (IC) per a cadascuna de les mètriques: `CI=scipy.stats.t.interval(confidence=0.95, df=len(data)-1, loc=np.mean(data),` `scale= scipy.stats.sem(data))`

Intervals de confiança del 95 % (NTrial = 30):

	AUC	**recall dígit**	**recall lletra**
SVM	[0,935 ; 0,953]	[0,758 ; 0,815]	[0,905 ; 0,932]
KNN	[0,884 ; 0,908]	[0,579 ; 0,665]	[0,915 ; 0,940]
MLP	[0,930 ; 0,952]	[0,710 ; 0,776]	[0,953 ; 0,974]

Quins se superposen? Compara'ls amb els rangs de l'Exercici 2. Calcula'ls per a diverses mostrejos *bootstrap* i compara els resultats. Compara la longitud (rang) dels intervals per a diferents valors de `NTrial`. PISTA: Entrena/prova per a `NTrial=50` i submostreja les mètriques.

quins se superposen?

- **AUC**: L'SVM i l'MLP se superposen gairebé del tot. El KNN queda sol per sota.
- **Recall de dígits:** l'SVM i l'MLP se superposen una mica. El KNN queda sol per sota.
- **Recall de lletres:** L'SVM i el KNN se suèrposen. L'MLP queda sol per sobre.

Comparació amb els rangs de l'Ex2: Mesuren coses diferents:

- **mitjana ± desviació:** diu com varia el resultat d'**una** partició a una altra (p.ex: l'AUC de l'SVM es mou ±0,024).
- **interval de confiança:** diu entre quins valors és la **mitjana real** del classificador, amb un 95% de confiança.

L'interval és molt més estret que el rang de la desviació. Per això amb els r'angs de l'Ex2 semblava que tot se superposava, però amb els intervals podem separar definitivament el KNN.

Amplada de l'interval segons NTrial. Hem entrenat 50 particions i hem calculat l'intervals de les n primeres:

n proves	AUC SVM	AUC KNN	AUC MLP	recall dígit SVM	recall dígit KNN	recall dígit MLP
5	0,075	0,102	0,042	0,260	0,403	0,118
10	0,032	0,049	0,033	0,114	0,194	0,078
20	0,025	0,032	0,031	0,081	0,124	0,067
30	0,018	0,025	0,022	0,057	0,086	0,066
50	0,014	0,020	0,016	0,046	0,063	0,054

Com més roves, més estret és l'interval. L'amplada baixa aproximadament com $1/\sqrt{n}$ (per fer-la la meitat cal multiplicar-la per 4 proves). També veiem com el centre de l'interval canvia poc a partir de n = 20. El que guanyem amb més proves és precisió.

b) Calcula una prova t de Student per a la mitjana de totes les parelles de classificadors: `TStudent,pval= scipy.stats.ttest_1samp`

Per a cada parell de classificadors, restem les mètriques de la mateixa prova (mateixa partició) i comprovem si la mitjana d'aquestes diferències és 0 (ttest_1samp(diferències, 0)). Estem comparant tots dos classificadors sobre les mateixes dades, i així treu la part de la variació que ve de si la partició és fàcil o difícil.

	AUC (p)	recall dígit (p)	recall lletra (p)
SVM – KNN	$1 \cdot 10^{-13}$	$3 \cdot 10^{-11}$	0,18
SVM – MLP	0,50	0,010	$2 \cdot 10^{-8}$
KNN – MLP	$4 \cdot 10^{-9}$	$5 \cdot 10^{-6}$	$6 \cdot 10^{-7}$

Quins són significativament diferents (`p-val<0.01`)? Si haguessis de calcular un classificador conjunt (*ensemble*), quins classificadors utilitzaries? Nota: Aquesta és una aproximació a una comparació exacta mitjançant ANOVA.

El **KNN** és significativament pitjor dels altres dos en AUC i en recall de dígits.
En **AUC** l'SVM i l'MLP no són significativament diferents (p = 0,05).
En **recall de lletres** l'MLP és significativament que els altres. L'SVM i el KNN no es diferencien.
En **recall de dígits** l'SVM contra MLP no és diferencien per just el limit del nivell de significació (p = 0,01). Amb 50 proves, p sí que baixa per sota i la diferència passa a ser significativa. El numero de proves importa.

Si haguessim de construir un ensamble seria el mateix que a l'Ex2 (SVM + MLP), però ara amb proves:

- totes dues tenen la mateixa AUC (no es poden distingir);
- són significativament diferents en el que fan bé: l'SVM en dígits (a 50 proves) i l'MLP en lletres;
- el KNN és significativament pitjor en AUC i en dígits, i no l'hi afegiríem.

*petita nota de l'ANOVA: fer molts t-tests per separat no és el mateix que una comparació conjunta (ANOVA de mesures repetides), i després comparar els parells, corregint per comparacions múltiples. Com diu l'enunciat, aquí ho aproximem.

Les 30 particions no són del tot independents: totes surten de les mateixes 432 mostres, i els conjunts de train es solapen molt. Per això els valors de p reals serien una mica més grans que els calculats. Les diferències molt clares ($p \sim 10^{-8}$ o menys) no canvien, però les del límit, com p = 0,010, s'han de llegir amb prudència.