UAB
Universitat Autònoma de Barcelona

Repte 1: Car Plate Recognition

1. Foto original i cantonades (YOLO-pose)



2. Rectificació per homografia



3. Segmentació: 7 regions



4. Màscares sense inclinació → CNN



5. Lectura final

4725DGT

Grup 7

Alícia Martí López, 1702761

Elena Gutiérrez del Burgo, 1703828

Alejandro Rodríguez Collado,1702654

Mètodes Avançats per al Processament de Senyal, Imatge i Vídeo

Data d’entrega 2 de novembre de 2026

1. Challenge Objectives

Durant el projecte hem desenvolupat un sistema automàtic capaç de trobar la matrícula d'un cotxe en una fotografia i llegir què hi posa. La fotografia pot tenir ombres, reflexos, altres cotxes o una matrícula molt petita, i si la imatge és lateral els caràcters queden deformats i ja no tenen la mateixa aparença que en una vista frontal.

L'objectiu és obtenir el text d'una matrícula espanyola de quatre dígits i tres lletres, com ara 0216KZP, a partir de la imatge completa. Hem separat el problema en localització, rectificació, segmentació i reconeixement. Ho hem fet així perquè, quan una lectura falla, ens interessa saber en quin punt hem perdut la informació i què podem canviar per recuperar-la.

Molts sistemes actuals llegeixen el text de cop amb xarxes que reconeixen seqüències [3, 4], però aquests models necessiten moltes imatges anotades, i el nostre corpus principal només té 251 fotografies. Per això hem mantingut un procés dividit en diverses etapes. D'una banda fem servir aprenentatge en aquelles tasques on tenim prou dades per entrenar el model, com ara la detecció de les cantonades o la classificació de cada caràcter (amb l'ajuda del conjunt públic UC3M-LP [5]). D'altra banda, per redreçar la imatge i separar els caràcters ens basem en operacions morfològiques directes.

Hem començat amb tècniques clàssiques de processament d'imatge, que ens han servit per entendre què diferencia una matrícula del fons. Al veure que les regles fixes es comportaven de manera diferent segons el tipus de fotografia, hem fet servir detecció apresa amb YOLO. Per llegir els caràcters vam començar amb descriptors HOG i SVM; en analitzar els errors vam veure que una sola lletra mal llegida feia fallar moltes matrícules, i al sistema final l'hem substituït per una xarxa convolucional petita.

2. Methodology

La Figura 1 mostra el recorregut d'una fotografia fins al text final. Un model YOLO-pose troba les quatre cantonades de la matrícula i, amb una homografia, la transformem en una vista frontal. Sobre aquest retall separem els caràcters, en corregim la inclinació i els classifiquem amb una CNN. Com que cap manera de retallar o de segmentar va bé a totes les fotografies, provem unes quantes alternatives i ens quedem amb la lectura més segura.

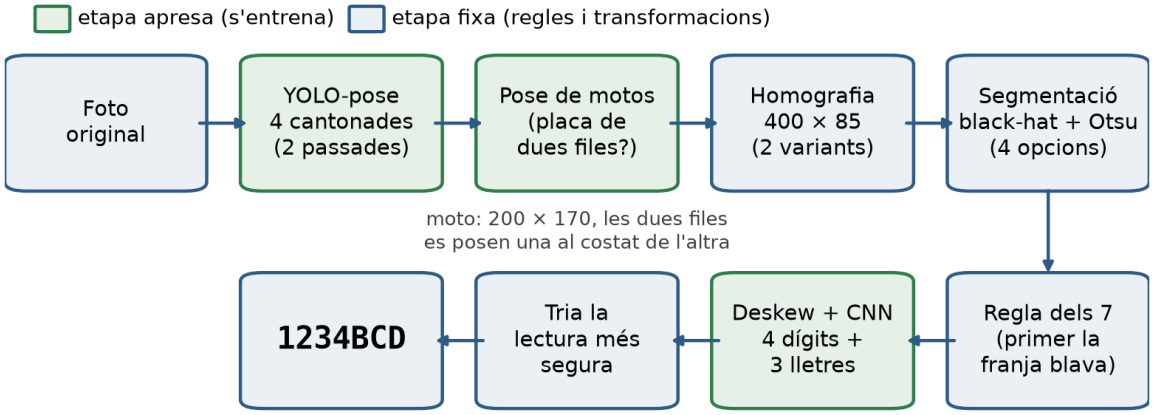


Figura 1. Pipeline del sistema final. En verd, les etapes que s'entrenen; en blau, les transformacions i regles fixes.

2.1 Localització de la matrícula

Fem servir YOLO [6] en la variant de pose, que aquesta a més de la caixa, prediu les quatre cantonades de la matrícula (superior esquerra, superior dreta, inferior dreta i inferior esquerra). Partim del model nano preentrenat amb COCO i l'ajustem amb les fotografies de train i una mostra d'UC3M.

Abans de passar la foto al model, l'ajustem a una mida de 640 x 640 píxels afegint-hi vores sense deformar la imatge. Un cop el model troba la matrícula, desfem aquest canvi per saber en quines coordenades original cau, i ens quedem només amb la predicció més segura.

Una matrícula llunyana ocupa pocs píxels, així que retallem un quadrat al voltant de la primera matrícula detectada (unes sis vegades més gran que la placa) i la tornem a passar una segona passada perquè s'hi pugui fixar amb més detall. A més, tenim un segon YOLO-pose, entrenat també amb fotos de moto d'UC3M, que només decideix quan veu una placa quasi quadrada (amplada / alçada < 2).

2.2 Rectificació

Amb les quatre cantonades calculem una homografia per redreçar la perspectiva del quadrilàter a un rectangle de 400 × 85 píxels. Hem triat aquestes mides perquè

mantenen exactament la mateixa proporció que una matrícula estàndard (que mesura 520 × 110 mm), i hi afegim un marge de 8 píxels al voltant.

Així els caràcters arriben a la segmentació amb la mateixa forma geomètrica en totes les fotografies. L'error del detector és sobretot vertical i un retall massa ajustat podria tallar les lletres, redrecem cada matrícula dues vegades: una amb les cantonades predites i una altra donant-li un 8 % més de marge per dalt i per baix. En el cas de les motos, la placa es redreça a 200 × 170 píxels i les seves dues files es col·loquen una al costat de l'altra.

2.3 Separació dels caràcters

Primer traiem la franja blava de la Unió Europea, que no conté caràcters. Per fer-ho el codi busca els píxels blaus situats a l'extrem esquerre de la matrícula (que ocupa aproximadament un 9 % de l'amplada) i, depenent de la prova, esborra o bé tota la zona rectangular o bé només les taques blaves detectades.

A continuació, apliquem filtres d'imatge (un black-hat i un llindar d'Otsu) per fer ressaltar només la tinta fosca sobre el fons clar, obtenint així una màscara en blanc i negre on només es veuen els traços. Llavors, agrupem aquestes taques i les filtrem: eliminem el soroll per mida, tornem a unir els trossos de les lletres que s'hagin pogut trencar verticalment (com una lletra 'C' partida) i descartem tot allò que toqui les vores o sigui massa estret, alt o desalineat, ja que sol correspondre a la línia del marc i no pas a una lletra.

Com que sabem del cert que busquem 7 caràcters, utilitzem aquesta regla per corregir petits errors. Si un cop netejat hem detectat més de 7 taques, primer esborrem qualsevol residu que hagi quedat a la zona de la franja blava; si no n'hi ha, descartem la taca que tingui la forma més diferent de la resta. Si, per contra, en tenim menys de 7, agafem la regió més ampla (que segurament són dos caràcters que han quedat enganxats) i la partim a trossos iguals.

2.4 Reconeixement

Abans d'intentar llegir quin símbol és cada taca, en corregim la inclinació (deskew, que ve de "des-inclinar"). Aquest efecte d'inclinació, com en cursiva, apareix quan la foto s'ha fet amb molta perspectiva o si la detecció no ha estat gaire ajudatada. Per solucionar-ho, calculem la inclinació conjunta dels set caràcters i els redrecem tots alhora amb la deformació horitzontal contrària.

Després cada màscara es redimensiona a 64 × 32 píxels i entra en una CNN petita de tres blocs convolucionals (32, 64 i 128 filtres, amb normalització per lots [8] i max-pooling), una capa de 128 unitats i una sortida per a cada dígit i lletra. A les quatre primeres posicions només acceptem dígits i a les tres últimes, les vint lletres de les matrícules espanyoles actuals (sense vocals, Ñ ni Q). Abans d'apostar per la CNN vam estar fent proves comparant-la amb tècniques més antigues com HOG, LBP o SVM per veure quina llegia millor, detallat a la secció 4.2.

Com que a les fases anteriors el sistema ha anat creant diverses variants (2 maneres diferents de rectificar la placa i 4 maneres de separar-ne la tinta), en total

fa fins a 8 intents diferents de llegir la mateixa matrícula. D'aquesta manera, obtenim un text complet de 7 caràcters i una nota de confiança per a cada intent.

Quan el model intenta llegir una lletra o un número, assigna una probabilitat a totes les opcions possibles. La seguretat d'un caràcter concret es calcula restant la puntuació de la seva primera opció i la de la segona. Si la màquina ho té claríssim, la diferència serà gran; en canvi, si dubta molt entre un '8' i una 'B', la diferència serà molt petita. Com que el text de la matrícula té set caràcters en total, la nota de confiança global de tot l'intent és, simplement, la nota del caràcter que la màquina ha vist menys clar de tots set.

A l'hora de decidir quin d'aquests 8 intents és el guanyador, el programa prioritza els que han aconseguit trobar 7 caràcters a la primera de forma "natural", sense recórrer a trucs (com el de forçar el tall d'una taca massa ampla). D'entre tots els intents que han separat bé els 7 caràcters sense forçar-los, es queda amb el que tingui la nota de confiança més alta.

2.5 Què aprèn cada part

YOLO aprèn a localitzar la matrícula i a predir les cantonades; la rectificació, la segmentació i el deskew són regles fixes; la CNN aprèn a classificar les màscares. Per entrenar la CNN fem servir els caràcters que produeix la mateixa segmentació sobre les matrícules de train, redreçades amb les cantonades anotades i amb les predites, quan la segmentació dona exactament set regions. Hi afegim 5.158 caràcters d'UC3M, etiquetats amb les caixes de caràcter anotades d'aquest conjunt.

3. Experimental Design

3.1 Dataset Description

Hem unificat les fotografies del campus virtual i els dos conjunts de captures pròpies (own i own_2). Després d'eliminar còpies repetides, el corpus principal conté 251 imatges i 259 matrícules anotades, perquè tenim fotografies amb més d'una matrícula. El ground truth recull el text, i les quatre cantonades. Totes les fotos tenen la matrícula de format 4 digits i 3 lletres. UC3M-LP [5] aporta 1.975 imatges més, però tots els seus textos tenen caràcters tapats per anonimització, de manera que no hi ha cap matrícula completa per avaluar. El dataset d'uc3m l'utilitzem per entrenar el reconeixedor i també (en menys quantitat) per entrenar el detector.

Hem apartat 20 fotografies amb motos o formats que el sistema no ha de llegir; les 231 restants tenen una matrícula de quatre dígits i tres lletres. UC3M-LP [5] aporta 1.975 imatges més, però tots els seus textos tenen caràcters tapats per anonimització, de manera que no hi ha cap matrícula completa per avaluar.

Font	Fotos	Train	Validació	Test
Campus virtual (cv)	69	48	11	10
Captures pròpies (own)	41	29	5	7
own_2	121	82	20	19
Corpus principal	**231**	**159**	**36**	**36**
UC3M	1.975	1.201	230	544

Taula 1. Fotografies per font i partició (1_11/splits.csv). Train, validació i test només compten fotos amb una matrícula objectiu de 4 dígits + 3 lletres; les apartades són motos i formats especials. UC3M manté la seva partició de reconeixement.

La partició (Taula 1) és estratificada per font i tipus de vista, amb una proporció aproximada de 70 / 15 / 15. Hem comprovat que no hi hagui fotografies repetides i que cap matrícula apareix en dos conjunts, igual que amb aquelles fotos nostres molt properes en el temps. Els retalls de caràcters hereten la partició de la imatge original. Així evitem entrenar amb una vista d'un vehicle i avaluar amb una altra de pràcticament igual. Hem entrenat els models només amb train i hem fet servir la validació per triar les variants.

3.2 Experiments

Hem fet quatre experiments: (1) comparar detectors; (2) comparar reconeixedors dins del pipeline complet; (3) afegir les millores finals una a una; i (4) avaluar el

sistema final, entrenat només amb train, davant de la versió anterior amb HOG + SVM. Per comparar reconeixedors fem una validació creuada de cinc parts sobre les 231 fotografies de cotxe: cada vehicle cau sempre a la mateixa part, i a cada volta el reconeixedor s'entrena amb les altres quatre. La resta del pipeline és la mateixa en tots els casos. Com a comprovació fora del nostre corpus vam reservar 120 fotografies d'UC3M que no s'han fet servir fins al final. Hem implementat el sistema en Python [1] amb PyTorch [12], OpenCV [13], scikit-learn [14] i scikit-image [15]. La Taula 2 recull la configuració.

Etapa	Configuració del sistema final
YOLO-pose (cotxes)	YOLOv8n-pose preentrenat amb COCO; 4 punts; 80 èpoques; entrada 640; batch 8; llavor 0; lr0 = 0,01 (optimitzador automàtic); gir ±10°, cisalla 2, perspectiva 0,0003, translació 0,1, escala 0,5, volteig horitzontal 0,5 (intercanviant les cantonades) i mosaic; millor època segons validació
YOLO-pose (motos)	el mateix amb gir ±25°, cisalla 5, perspectiva 0,0005 i 60 èpoques
Localització	2a passada en un retall quadrat de costat (1 + 2 · 2,5) vegades la mida de la matrícula
Rectificació	homografia a 400 × 85 px + 8 px de marge; 2a variant +8 % d'alçada per dalt i per baix
Segmentació	black-hat 34 × 34 + Otsu; regions d'alçada ≥ 25 % i amplada ≤ 50 % de la placa; franja: zona del 9 % esquerre
CNN	3 blocs (2 conv. 3 × 3 + BN + ReLU, max-pooling) de 32, 64 i 128 filtres; capa de 128 amb dropout 0,3; entrada 64 × 32; 33 classes; AdamW (lr $2 \cdot 10^{-3}$, decaïment 10^{-4}), cicle únic fins a $3 \cdot 10^{-3}$; 30 èpoques; batch 128; suavitzat d'etiquetes 0,05
Augmentació (CNN)	gir ±6°, escala 0,85–1,12, cisalla ±0,15, desplaçament ±8 %; traç més gruixut o prim (40 %); vores retallades (30 %)

Taula 2. Paràmetres principals del sistema final.

3.3 Metrics

Per a la localització comparem la regió predita B amb l'anotació G mitjançant IoU = àrea(B ∩ G) / àrea(B ∪ G) i reportem mAP50–95, la mitjana de la precisió mitjana per a llindars d'IoU de 0,50 a 0,95, tant per a la caixa com per als punts.

En reconeixement, l'encert de matrícula és el nombre de fotografies amb els set caràcters correctes dividit pel nombre de fotografies, i l'encert per caràcter compara les posicions del text. Per exemple, llegir 0216KXP en lloc de 0216KZP dona sis caràcters correctes de set, però cap matrícula correcta. Si una fotografia té més d'una matrícula, n'hi ha prou de llegir-ne una. Sempre donem el nombre d'encerts i el total, a més del percentatge.

Per a la validació creuada resumim cada mètode amb la mitjana i la desviació estàndard de les cinc parts. L'interval de confiança del 95 % de la mitjana és $\bar{x} \pm t(0{,}975;\ 4) \cdot s / \sqrt{5}$, on $\bar{x}$ és la mitjana, s la desviació mostral i t el quantil de t-Student. Per comparar dos mètodes fem un test t de les diferències sobre les mateixes cinc parts, amb el criteri $p < 0{,}01$. Per a un sol conjunt donem la proporció p amb l'interval $p \pm 1{,}96 \cdot \sqrt{p(1 - p)/n}$. Amb només cinc parts, una diferència no significativa no demostra que dos mètodes siguin equivalents.

4. Results

4.1 Detecció

La Taula 3 compara tres YOLO-pose entrenats 50 èpoques. Tots tenen un mAP50–95 de punts entre 0,951 i 0,966, però la lectura completa en validació va de 26 a 33 matrícules de 36. El model iniciat amb COCO i amb 53 fotografies d'UC3M (B) és el millor en punts i en lectura, tot i que no té el millor mAP de caixa: una bona caixa no garanteix bones cantonades. A partir de B hem afegit la segona passada, una augmentació suau de gir, cisalla i perspectiva i les fotos de moto d'UC3M; aquest és el pose del sistema final. També hem provat models més grans o amb més resolució, sense una millora clara.

Model	Dades d'ajust	mAP50–95 caixa	mAP50–95 punts	Pipeline (val.)
YOLOv8n caixes, inici COCO (S3)	corpus (partició antiga)	0,867	—	—
YOLOv8n caixes, inici LP (S3)	corpus (partició antiga)	0,824	—	—
A: pose, inici COCO	train 1_11	0,838	0,962	26/36
B: pose, inici COCO + UC3M	train 1_11 + 53 UC3M	0,788	0,966	33/36
C: pose, des de zero + UC3M	train 1_11 + 53 UC3M	0,746	0,951	27/36

Taula 3. Detecció en validació. Les files S3 són de la sessió 3 (100 èpoques); A, B i C, de 50 èpoques amb la partició 1_11. La darrera columna és la lectura completa amb el reconeixedor HOG + SVM d'aquell moment.

4.2 Reconeixement

La Taula 4 i la Figura 2 comparen els reconeixedors dins del pipeline complet. L'SVM amb HOG llegeix 212 de 231 fotografies. LBP funciona pitjor sobre màscares binàries (195). El retrieval funciona, però és una mica pitjor que la classificació directa: 208 amb HOG i 215 amb l'embedding de la CNN. Corregir la inclinació i afegir caràcters d'UC3M porta l'SVM a 218, i la CNN amb les mateixes dades arriba a 224 (97,0 ± 3,6 % per part).

Reconeixedor	Correctes	Caràcters	Parts: mitjana ± d.e.	IC 95 %
HOG + SVM	212/231	97,2 %	91,8 ± 6,2 %	84,0–99,5
LBP + SVM	195/231	95,4 %	84,4 ± 7,8 %	74,7–94,0
Retrieval 1-NN amb HOG	208/231	96,8 %	90,0 ± 6,3 %	82,2–97,8
HOG + SVM, amb deskew i UC3M	218/231	97,6 %	94,4 ± 4,2 %	89,1–99,6

Retrieval 1-NN amb l'embedding de la CNN	215/231	97,3 %	93,1 ± 5,6 %	86,1–100
CNN, amb deskew i UC3M (final)	**224/231**	**98,2 %**	**97,0 ± 3,6 %**	**92,4–100**

Taula 4. Pipeline complet amb cada reconeixedor: validació creuada de 5 parts per vehicle sobre les 231 fotos de cotxe.

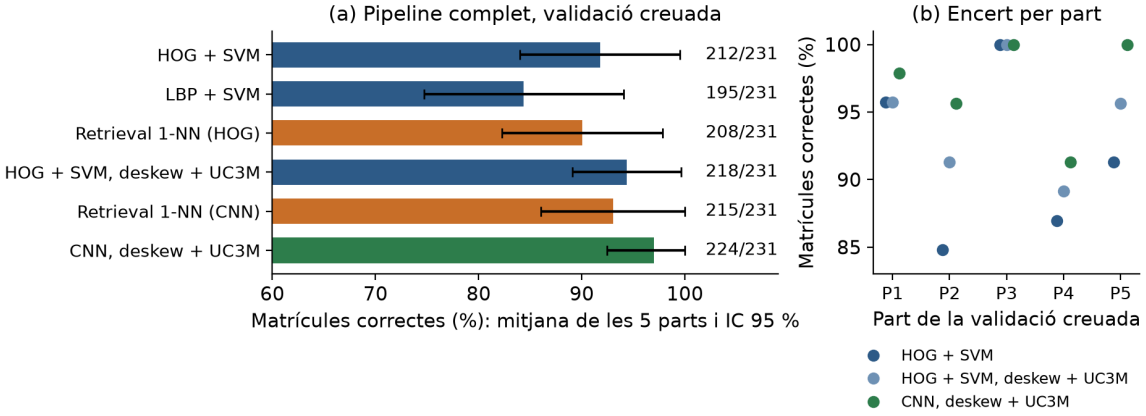


Figura 2. (a) Encert de matrícula de cada reconeixedor (mitjana de les 5 parts i IC del 95 %); (b) encert de l'SVM, de l'SVM amb deskew i UC3M i de la CNN a cada part.

La CNN iguala o supera l'SVM a les cinc parts (Figura 2b), però amb el criteri $p < 0{,}01$ la diferència no és significativa: 5,2 punts de mitjana davant de l'SVM inicial ($p = 0{,}061$) i 2,6 punts davant de l'SVM amb deskew i UC3M ($p = 0{,}033$). Amb cinc parts el test té poca potència, i per això ho llegim com una millora consistent però no demostrada.

4.3 Millores finals

Amb la CNN, la majoria dels errors que quedaven es recuperaven si fèiem servir les cantonades anotades: el problema era el retall. La Taula 5 mostra les dues millores que hem afegit, una cada vegada com en un estudi d'ablació [2], i sense perdre cap fotografia que ja funcionava.

Canvi (un cada vegada)	Correctes / 231	Test	Guanya / perd
CNN + deskew	224	32/36	—
+ variant de la placa un 8 % més alta	226	34/36	+2 / −0
+ primer la regió de la franja (final)	**227**	**35/36**	**+1 / −0**

Taula 5. Construcció del sistema final amb el pose i la CNN entrenats només amb train.

4.4 Avaluació final

La Taula 6 compara el sistema final amb la versió anterior sobre les mateixes fotografies. Amb el pose i el reconeixedor entrenats només amb train, el sistema final llegeix 35 de 36 matrícules de validació i 35 de 36 de test, davant de 34 i 32 de la versió amb HOG + SVM. Sobre les 231 fotografies de cotxe, la CNN n'encerta 7 més i no en perd cap.

Conjunt	Fotos	HOG + SVM (anterior)	CNN
Train	159	154 (96,9 %)	157 (98,7 %)
Validació	36	34 (94,4 %)	35 (97,2 %)
Test	36	32 (88,9 %)	35 (97,2 %)
cv / own / own_2	69 / 41 / 121	69 / 37 / 114	69 / 40 / 118
Caràcters (231 cotxes)	1.617	97,8 %	99,2 %

Taula 6. Avaluació final de tres sistemes amb el mateix protocol (millora/avalua.py). Tots fan servir el mateix YOLO-pose, entrenat amb train.

A les 120 fotografies reservades d'UC3M llegim sols els caràcters visibles, redreçant la placa amb el polígon anotat. L'SVM n'encerta 387 de 409 (94,6 ± 2,2 %) i la CNN, 401 (98,0 ± 1,4 %). El pipeline complet, en canvi, només encerta el 16,9 % dels caràcters visibles d'aquestes fotos, tot i trobar la matrícula en el 83,8 % dels casos: les taques d'anonimització trenquen la segmentació.

La Figura 3 mostra els quatre errors que queden a les fotografies de cotxe i una moto. A 9557HDT i 3044JMB les cantonades tallen la placa per un costat; a 3275JFB la J i la F queden enganxades, i a 1280CNG la C es trenca en la binarització. Les motos es localitzen, però les cantonades encara no són prou precises.



Figura 3. Errors del sistema final: retall amb les cantonades predites (a dalt) i matrícula redreçada (a baix).

Finalment, la Taula 7 recull els enviaments a Codabench, totes versions amb HOG + SVM.

Data	Sistema enviat	Matrícules	Caràcters
29-oct	model_v2 (pose antic + HOG + SVM), dos enviaments	82 i 83 / 102	0,888 i 0,901
1-nov	pose B + HOG + SVM	88 / 102 (0,863)	0,905
2-nov	pose B en 2 passades + 4 segmentacions + HOG + SVM	88 / 102 (0,863)	0,920
2-nov	pose I + pose de motos + HOG + SVM (2_11)	84 / 102 (0,824)	0,909

Taula 7. Resultats a Codabench (102 fotos de desenvolupament dels professors).

5. Discussion and Conclusions

Hem connectat detecció, rectificació, segmentació i reconeixement en un únic sistema que, amb els models entrenats només amb train, llegeix 227 de 231 fotografies de cotxe del nostre corpus (35 de 36 en validació i en test).

La comparació de detectors ens ha fet veure que les mètriques de detecció no ordenen els models igual que la lectura final: petits errors de cantonades poden tallar un caràcter. El canvi que més ha aportat és el reconeixedor. Amb l'SVM, el 97 % per caràcter semblava alt, però una sola lletra incorrecta ja fa fallar la matrícula sencera. La CNN, el deskew i els caràcters d'UC3M milloren a totes les proves, també als caràcters reservats d'UC3M, tot i que amb cinc parts la diferència no arriba a ser significativa.

La segmentació continua sent el punt més delicat. Els errors que queden demanen cantonades més precises per a plaques molt girades, que caldria abordar amb més exemples per al YOLO-pose, i una manera de separar caràcters enganxats, per exemple provant diversos talls i quedant-se el que la CNN veu més segur. Per a les motos caldrien més fotografies anotades.

Ens quedem amb la idea pràctica de que millorar una etapa només és útil si aquesta millora arriba al text final.

6. Contributions & IA Usage

6.1 Contribucions de l'equip

Durant les primeres setmanes ens vam dividir més segadament la feina, ja que volíem preparar un bon dataset prou variat, unes anotacions fiables i una separació correcta entre entrenament, validació i test. En aquesta primera etapa sí que ens vam repartir més les tasques, perquè cadascú pogués avançar en una part.

Després de l'analisi de les dades del campus virtual L'Alícia va definir un protocol d'adquisició de dades i va anar al pàrquing a fer més fotografies per construir el conjunt propi, amb algunes fotos que seguien el protocol i altres que l'incomplien. També es va encarregar d'obtenir el ground truth de totes les imatges. Revisant les fotografies i anotar correctament les matrícules per poder entrenar i avaluar el sistema. Ja que si les anotacions no són fiables, després és difícil saber si un error ve del model o de la referència amb què el comparem.

L'Elena es va encarregar de buscar el dataset UC3M i de preparar les particions corresponents. Va revisar que les fotografies d'una mateixa matrícula quedessin sempre dins del mateix conjunt, encara que fossin imatges diferents. Vam considerar important fer aquesta separació per evitar que el model s'entrenés amb una matrícula i després s'avalués amb una altra fotografia d'aquesta, cosa que podia donar uns resultats massa optimistes.

L'Alejandro es va encarregar d'organitzar els fitxers inicials i d'estructurar les carpetes del projecte. Va deixar ordenats les dades, les anotacions i els scripts

perquè tots tres poguéssim localitzar fàcilment el material i treballar sobre una estructura comuna.

Vam construir una eina interactiva per facilitar l'anotació de la groundtruth i entre tots ens vam repartir les 162 fotos dels dos conjunts propis per anotar-les i dividir-nos la feina.

Després vam treballar conjuntament a classe en les activitats del campus virtual, provant les diferents opcions de cada etapa. L'Alícia va fer les proves i reentrenar els detectors YOLO-pose, l'Elena va dissenyar la segmentació del sistema i l'Alejandro es va dedicar a les proves reconeixedor.

Entre tots ens anavem comunicant els resultats per coordinar l'avaluació final.

6.2 Ús de la intel·ligència artificial

Hem utilitzat un assistent de programació basat en un model de llenguatge (Claude Code, d'Anthropic) en la part final del projecte: per escriure i modificar scripts d'entrenament i d'avaluació, executar experiments, analitzar errors i redactar aquesta versió de l'informe a partir d'un l'informe previ redactat per nosaltres de manera menuys formal. Les decisions i la revisió dels resultats són nostres, i cada valor surt d'un fitxer de resultats que es pot reproduir amb el codi entregat.

7. References

[1] Python Software Foundation. Python, www.python.org. Data d'accés: 2 de novembre de 2026.

[2] Meyes, R., Lu, M., de Puiseau, C. W., & Meisen, T. (2019). Ablation studies in artificial neural networks. arXiv preprint arXiv:1901.08644.

[3] Shi, B., Bai, X., & Yao, C. (2017). An end-to-end trainable neural network for image-based sequence recognition and its application to scene text recognition. IEEE TPAMI, 39(11), 2298–2304.

[4] Zherzdev, S., & Gruzdev, A. (2018). LPRNet: License plate recognition via deep neural networks. arXiv preprint arXiv:1806.10447.

[5] Ramajo-Ballester, Á. UC3M-LP Dataset. Universidad Carlos III de Madrid, e-cienciaDatos (2023). https://doi.org/10.21950/OS5W4Z

[6] Jocher, G., Chaurasia, A., & Qiu, J. (2023). Ultralytics YOLOv8. https://github.com/ultralytics/ultralytics

[7] Otsu, N. (1979). A threshold selection method from gray-level histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62–66.

[8] Ioffe, S., & Szegedy, C. (2015). Batch normalization: Accelerating deep network training by reducing internal covariate shift. ICML, 448–456.

[9] Dalal, N., & Triggs, B. (2005). Histograms of oriented gradients for human detection. CVPR, 886–893.

[10] Ojala, T., Pietikäinen, M., & Mäenpää, T. (2002). Multiresolution gray-scale and rotation invariant texture classification with local binary patterns. IEEE TPAMI, 24(7), 971–987.

[11] Cortes, C., & Vapnik, V. (1995). Support-vector networks. Machine Learning, 20(3), 273–297.

[12] Paszke, A., et al. (2019). PyTorch: An imperative style, high-performance deep learning library. NeurIPS 32.

[13] Bradski, G. (2000). The OpenCV Library. Dr. Dobb's Journal of Software Tools.

[14] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. JMLR, 12, 2825–2830.

[15] van der Walt, S., et al. (2014). scikit-image: image processing in Python. PeerJ, 2, e453.